CLASIFICACIÓN SUPERVISADA DE UNIDADES GEOPEDOLÓGICAS PARA LA CUENCA DEL RÍO CEIBO, BUENOS AIRES, PUNTARENAS

Bach. Alexander Tencio Moya, carné B97801

"Proyecto de graduación presentado al Comité Examinador de la Escuela de Geografía para el cumplimiento de requisitos para obtener el grado de Licenciatura en Geografía"

"Enero, 2026"

Dr. Adolfo Quesada Román, Director

Dr. Manuel Camacho Umaña, Lector

M.Sc. Luis Guillermo Artavia Rodríguez, Lector

TRIBUNAL EXAMINADOR DE LA DEFENSA ORAL Y PÚBLICA PARA OPTAR POR EL GRADO DE LICENCIATURA EN GEOGRAFÍA.

Título del trabajo final de graduación:

Clasificación supervisada de unidades Geopedológicas para la cuenca del río Ceibo, Buenos Aires, Puntarenas

M.Sc. Melvin Lizano Araya

Presidente del Tribunal Examinador

Lic. Manfred Salas Castro

Profesor invitado

Dr. Adolfo Quesada Román

Director del Comité Asesor

Dr. Manuel Camacho Umaña

Lector (a) del Comité Asesor

Luis Guillermo Artavia R.

M.Sc. Luis Guillermo Artavia Rodríguez

Lector (a) del Comité Asesor

Alexander Tencio Moya

Sustentante

Dedicatoria

A mi familia por todo el apoyo brindado e inculcarme seguir adelante con el estudio y a mi persona por nunca dar el brazo a torcer en los momentos difíciles.

Agradecimientos

Agradezco a mis amigos de la universidad Daniel Cruz García, Melany Camacho Segura y David Young Fuentes que me dieron un gran apoyo, enseñanzas y una lealtad invaluable. A todas esas personas que aportaron en conocer la gran comunidad de Buenos Aires que por ellos sentí una gran cercanía para aportar un granito de arena y a Franchesca García, quien me ayudo con su paciencia y apoyo para continuar con este gran reto.

Un agradecimiento muy especial a mi comité asesor Adolfo Quesada Román, Luis Guillermo Artavia Rodríguez y Manuel Camacho Umaña por su gran apoyo, orientación y educación me suministraron grandes valores geográficos como de crecimiento personal en este camino a la profesionalización de mi futuro.

Por último, agradezco al Laboratorio de Geografía Física por ese espacio seguro para investigar lo que no llena, por todas esas experiencias vividas y por hacerme sentir en casa. Al Centro de Investigaciones Agronómicas (CIA) al ser uno de los espacios que siempre me acercaron a la temática.

CLASIFICACIÓN SUPERVISADA DE UNIDADES GEOPEDOLÓGICAS PARA LA CUENCA DEL RÍO CEIBO, BUENOS AIRES, PUNTARENAS

Resumen: La caracterización espacial de los suelos en regiones tropicales montañosas representa un desafío debido a la compleja interacción entre factores geomorfológicos, climáticos y pedológicos, así como a la limitada disponibilidad de información obtenida en el campo. Este estudio clasifica unidades geopedológicas mediante aprendizaje automático supervisado en la cuenca del río Ceibo, ubicada en el cantón de Buenos Aires de Puntarenas, Costa Rica, mediante análisis geomorfológico, variables ambientales y modelos de aprendizaje automático. Se emplearon 1 243 observaciones de perfiles de suelo georreferenciados y clasificados según el sistema Soil Taxonomy del USDA, en conjunto con once variables predictoras representativas de los factores formadores del suelo.

Se implementaron y compararon tres algoritmos de clasificación supervisada: Random Forest, Extreme Gradient Boosting (XGBoost) y CatBoost, y se evalúa su desempeño mediante exactitud global, coeficiente Kappa y métricas F1 ponderadas y macro. Se obtuvo como resultado que XGBoost presentó el mejor desempeño predictivo, con una exactitud global del 96,2 % y un coeficiente Kappa de 0,941, seguido por Random Forest y CatBoost. Las variables más influyentes fueron la elevación, la temperatura máxima y las métricas geomorfométricas, lo que confirma el fuerte control topoclimático sobre la distribución de los órdenes de suelos.

La cartografía resultante evidencia el predominio de Ultisoles en las tierras bajas y medias, la presencia de Andisoles en zonas de mayor altitud y la distribución de Inceptisoles y Entisoles en áreas de transición geomorfológica y fluvial. A partir de estos resultados se proponen unidades geopedológicas integradas, útiles para el ordenamiento territorial y la gestión ambiental en regiones con escasa información pedológica.

Palabras clave: Geopedología; mapeo digital de suelos; modelo predictivo; XGBoost.

INTRODUCCIÓN

La caracterización y cartografía de los suelos constituye un insumo fundamental para la planificación territorial, la gestión ambiental y la toma de decisiones en regiones con alta complejidad geomorfológica y climática (Hengl et al., 2017). En zonas tropicales montañosas, como el sur de Costa Rica, la distribución espacial de los suelos responde a interacciones complejas entre el relieve, el clima, el material parental, la cobertura vegetal y los procesos geomorfológicos activos, según el modelo conceptual CLORPT de Jenny (1941). Sin embargo, los estudios de suelos detallados en estas regiones continúan con limitaciones de información, particularmente los que integran enfoques geopedológicos con herramientas modernas de análisis espacial y modelación predictiva (Wadoux et al., 2019).

La cuenca del río Ceibo, ubicada en el cantón de Buenos Aires de Puntarenas, representa un territorio de alto interés geográfico debido a su marcada heterogeneidad altitudinal, diversidad geomorfológica y relevancia socioambiental. A pesar de su importancia para la actividad agrícola, la disponibilidad hídrica y la conservación ambiental, esta cuenca carece de una caracterización geopedológica integral que permita comprender la distribución y dinámica de sus suelos. Esta ausencia de información constituye una limitación significativa para el ordenamiento territorial, la gestión del riesgo y el aprovechamiento sostenible del espacio geográfico.

En este contexto, la geopedología surge como un enfoque que integra las formas del relieve con los procesos de formación del suelo, lo que permite delimitar unidades geopedológicas como entidades homogéneas desde el punto de vista geomorfológico y pedológico (Buytaert et al., 2006). La incorporación de metodologías de clasificación automatizada, modelos digitales de elevación y datos geoespaciales como los geomorfones ha ampliado las posibilidades de análisis espacial, lo que facilita la identificación objetiva de patrones del paisaje a distintas escalas (Hengl et al., 2017). Paralelamente, el avance de los métodos de aprendizaje automático ha abierto nuevas oportunidades para la predicción espacial de suelos, especialmente en contextos donde la información obtenida mediante estudios de campo es limitada o costosa. Algoritmos como Random Forest, XGBoost y CatBoost han demostrado un alto potencial para modelar relaciones no lineales entre las variables ambientales y las clases de suelos lo que permite generar mapas predictivos con altos niveles de precisión y reproducibilidad (Aydin et al., 2023; Wadoux et al., 2020). El presente estudio tiene como objetivo caracterizar la geopedología de la cuenca del río

Ceibo mediante análisis geomorfológico, variables ambientales y modelos de aprendizaje automático y utiliza el sistema de clasificación Soil Taxonomy del USDA.

Este estudio compara el desempeño de tres algoritmos supervisados (Random Forest, XGBoost y CatBoost) para identificar los órdenes de suelos predominantes y proponer unidades geopedológicas, que sirvan como base para la planificación territorial y la gestión ambiental en una región históricamente poco estudiada desde la geografía física aplicada. Este enfoque metodológico sigue las mejores prácticas establecidas por Hengl et al. (2017) para pedometría digital y aprovecha los avances recientes en algoritmos de gradient boosting aplicados a la clasificación de suelos (Aydin et al., 2023; Zhao et al., 2021).

MARCO REFERENCIAL

La geopedología es un campo interdisciplinario que integra la geomorfología y la pedología para estudiar cómo los procesos que moldean el relieve terrestre influyen en la formación, evolución y distribución espacial de los suelos (Zinck et al., 2023).

La geomorfología es clave para este análisis, ya que se encarga de estudiar las formas del terreno y sus procesos de formación, centrándose en la génesis y evolución de las estructuras que vemos en el paisaje. Estos procesos, como la erosión, la tectónica o la sedimentación, actúan en diferentes escalas temporales y espaciales, transforman continuamente la superficie terrestre (Gómez-Guzmán, 2005). Dentro de la geomorfología, las geoformas son las manifestaciones físicas de estos procesos; es decir, las formas visibles del relieve, como montañas, valles, colinas y llanuras. Estas geoformas representan la interacción de múltiples agentes geológicos, climáticos y biológicos que, a lo largo del tiempo, moldean la estructura del terreno (Zinck et al., 2023).

En la práctica, la geopedología permite establecer cómo las características geomorfológicas del terreno determinan las propiedades físicas, químicas y biológicas de los suelos. Los suelos se clasifican taxonómicamente en categorías jerárquicas, siendo los órdenes la unidad de mayor nivel (Soil Survey Staff, 1999). Ejemplos comunes incluyen los Ultisoles, Oxisoles, Inceptisoles y Entisoles, que se diferencian por su génesis, composición y propiedades (Camacho et al., 2020). La interrelación entre las geoformas y los tipos de suelos da como resultado lo que se conoce como unidades geopedológicas, áreas geográficas homogéneas que combinan las características del relieve con las del suelo. Estas unidades permiten clasificar y cartografiar territorios en función de las condiciones geomorfológicas y edáficas, lo que facilita una comprensión integral del entorno

físico. Esta clasificación es útil para la planificación del uso del suelo, la gestión de recursos y la toma de decisiones en el ámbito económico, agrícola o ambiental (Camacho et al., 2020).

Análisis espacial y geopedología digital

El análisis espacial constituye un componente central en los estudios geopedológicos contemporáneos, ya que permite integrar información ambiental multifuente y analizar patrones espaciales complejos asociados a la distribución de los suelos. Mediante el uso de Sistemas de Información Geográfica (SIG), es posible relacionar variables topográficas, climáticas y geomorfológicas con observaciones puntuales de suelo, lo que facilita la generación de modelos predictivos espacialmente explícitos (Hengl et al., 2017; Wadoux et al., 2019).

Teoría de la Formación del Suelo

La formación del suelo es un proceso complejo que depende de la interacción entre cinco factores principales: material parental, relieve, clima, organismos vivos, y tiempo. Hans Jenny formalizó esta idea en su obra (Jenny 1941), proporciona un marco que sigue una linealidad central en los estudios pedológicos contemporáneos. Según esta teoría, los materiales parentales son los que proporcionan esa base donde iniciar el proceso físico y químico, posteriormente el relieve determina la redistribución de materiales y la exposición del suelo a los agentes de erosión y acumulación. El clima regula procesos como la meteorización química y la lixiviación, mientras que los organismos influyen en la producción de materia orgánica y en la bioturbación. Por su parte, el material parental aporta los componentes minerales que servirán como base para el desarrollo del perfil del suelo, y el tiempo condiciona la madurez y el grado de evolución del suelo.

En el contexto de la identificación de unidades geopedológicas, esta teoría es crucial, ya que permite comprender las diferencias espaciales en la composición y estructura de los suelos. Por ejemplo, en áreas con mayor pendiente, el relieve limita el desarrollo del suelo debido a la erosión superficial, mientras que en zonas planas se favorece la acumulación de sedimentos y el desarrollo de horizontes más profundos. Al integrar esta teoría en el análisis geopedológico, se logra una interpretación más precisa de las variaciones en el paisaje (Jenny 1941).

Sistema de Clasificación de Suelos Soil Taxonomy del USDA

El Soil Taxonomy (Soil Survey Staff 1999) es un sistema de clasificación desarrollado por el USDA (United States Department of Agriculture), el cual es uno de los sistemas de clasificación de suelos más ampliamente utilizados en estudios de suelos y ordenamiento territorial. Este sistema organiza los suelos en una jerarquía taxonómica que incluye seis niveles principales: Orden, Suborden, Gran grupo, Subgrupo, Familia taxonómica y Serie taxonómica.

A nivel global, incluye 12 órdenes, entre los que destacan los Oxisoles, Ultisoles, Andisoles, Mollisoles, Alfisoles, Entisoles e Inceptisoles, Histosoles, Espodosoles y Vertisoles cada uno definido por características diagnósticas específicas, como horizontes ricos en materia orgánica, acumulación de arcillas o desarrollo mínimo de perfiles (Soil Survey Staff, 2022). La principal fortaleza del Soil Taxonomy radica en su enfoque en características observables y mensurables, como horizontes diagnósticos (mollico, argílico, espódico, entre otros) así como propiedades químicas y físicas específicas (Soil Survey Staff, 2022). Esto permite una clasificación consistente y replicable en diversas regiones del mundo. En el contexto de la identificación de unidades geopedológicas, el Soil Taxonomy proporciona un marco sólido para interpretar cómo los suelos reflejan los procesos geomorfológicos y las condiciones ambientales de un área determinada. Por ejemplo, la presencia de Entisoles en áreas con alta pendiente puede indicar procesos activos de erosión, mientras que los Mollisoles en valles aluviales suelen reflejar condiciones más estables y fértiles.

Metodología de los Geomorfones

La metodología de los geomorfones (Geomorphons en inglés), propuesta por Jasiewicz & Stepinski (2013), utiliza un enfoque basado en patrones para identificar y clasificar formas del terreno de manera automatizada. Los geomorphons representan unidades geomorfológicas fundamentales, como valles, colinas, cumbres y pendientes, que se derivan directamente de datos de modelos digitales de elevación (MDE o DEM por su siglas en inglés) de ALOS PALSAR (JAXA, 2006). Este método no solo permite clasificar rápida y objetiva, sino que también es altamente replicable, lo que resulta ventajoso para el análisis de grandes áreas geográficas. En el análisis geopedológico, esta metodología juega un papel destacado, ya que las formas del terreno tienen una relación directa con los procesos de formación y distribución del suelo.

Además, facilita la generación de la cartografía geomorfológica o morfogenética, "reduce significativamente el tiempo requerido en comparación con métodos convencionales (Quesada-Román & Peralta-Reyes, 2023). Por ejemplo, las áreas cóncavas tienden a acumular materiales y agua, favorece la formación de suelos profundos y ricos en materia orgánica, mientras que las áreas convexas suelen estar sujetas a una mayor erosión, lo que da lugar a suelos menos desarrollados. La integración de los geomorphons en sistemas de información geográfica (SIG) permite combinar información topográfica y pedológica, facilita la delimitación de unidades geopedológicas de manera precisa y eficiente (Jasiewicz & Stepinski, 2013).

Random Forest

Random Forest es un algoritmo de aprendizaje conjunto (ensemble learning) propuesto por Breiman (2001) que construye múltiples árboles de decisión durante el entrenamiento y emite la clase modal de las predicciones individuales. Su robustez proviene de dos principios fundamentales: bagging (bootstrap aggregating), donde cada árbol se entrena con una muestra aleatoria con reemplazo del conjunto de datos original, y selección aleatoria de características, donde en cada división del árbol solo se considera un subconjunto aleatorio de variables predictoras (Cutler et al., 2012).

La predicción final ($\hat{y}$) para clasificar se obtiene mediante un voto mayoritario estimado mediante la siguiente ecuación:

$$\hat{y} = mode\{h_1(x), h_2(x), \ldots, h_n(x)\}$$ **Ecuación 1**

Donde h_n representa cada árbol individual (n). En mapeo digital de suelos, Random Forest ha demostrado resultados exitosos en diversos contextos: Heung et al., (2016) reportaron similitudes superiores al 70% en la clasificación de órdenes de suelos en British Columbia usa variables topográficas y climáticas; Taghizadeh-Mehrjardi et al., (2020) lograron predicciones precisas de clases de suelos en regiones áridas de Irán; mientras que Mallavan et al., (2010) encontraron limitaciones en áreas con alta heterogeneidad geológica donde el modelo presentó confusiones entre subórdenes similares.

Extreme Gradient Boosting (XGBoost)

El algoritmo XGBoost (Bentéjac et al., 2021) es una implementación optimizada de gradient boosting que construye árboles de decisión de manera secuencial, donde cada árbol nuevo intenta corregir los errores de los árboles anteriores. A diferencia de Random Forest, (que entrena árboles en paralelo y de forma independientes), XGBoost emplea un enfoque aditivo donde cada árbol aprende de los residuos del modelo previo, permiten capturar patrones progresivamente más complejos (Hastie et al., 2009). El modelo se construye iterativamente mediante:

$$F_m(x) = F_\{m-1\}(x) + \eta \cdot h_m(x)$$ **Ecuación 2**

Donde F_m es el modelo en la iteración m, η es la tasa de aprendizaje, y h_m es el árbol que minimiza la función de pérdida. En mapeo digital de suelos, XGBoost ha mostrado rendimiento superior en múltiples estudios. Por ejemplo: Padarian et al., (2019) alcanzaron similitudes del 85% en la predicción de propiedades de suelos en Australia usa covariables ambientales; Ramcharan et al., (2018) obtuvieron mejores resultados que Random Forest en la clasificación de horizontes de suelos en Uganda; sin embargo, Viscarra et al., (2011) reportaron casos de sobreajuste cuando el conjunto de entrenamiento era limitado o presentaba desbalance entre clases.

Categorical Boosting (CatBoost)

Por último, el método CatBoost (Prokhorenkova et al., 2018) es un algoritmo de gradient boosting desarrollado por Yandex (empresa tecnológica multinacional rusa especializada en productos y servicios de Internet, incluyendo motores de búsqueda, comercio electrónico, y desarrollo de tecnologías de inteligencia artificial y aprendizaje automático) que introduce dos innovaciones fundamentales: un esquema de codificación de variables categóricas basado en estadísticas ordenadas (ordered target statistics) que previene el sobreajuste causado por la fuga de información (target leakage), y árboles de decisión oblivious donde todos los nodos a la misma profundidad utilizan la misma condición de división.

La codificación de variables categóricas se realiza mediante la siguiente ecuación:

$$TS(x_i) = \Sigma(y_j \cdot I(x_j = x_i)) / (\Sigma I(x_j = x_i) + p)$$ **Ecuación 3**

Donde *TS* es la estadística objetivo, *y_j* son los valores objetivo, *p* es un parámetro de suavizado que previene el sobreajuste. En mapeo digital de suelos, CatBoost ha demostrado ventajas específicas: Wadoux et al., (2020) reportaron mejor manejo de variables categóricas geológicas en Holanda comparado con Random Forest y XGBoost; Zhao et al., (2021) lograron clasificaciones precisas de tipos de suelos en China usa CatBoost con variables categóricas de uso de suelo y geomorfología; aunque Zhang et al., (2019) encontraron que en datasets pequeños el modelo puede presentar inestabilidad debido a su complejidad algorítmica.

OBJETIVOS DE INVESTIGACIÓN

La presente investigación integra tres modelos predictivos de aprendizaje automático que emplean variables físico-ambientales para aproximar la distribución espacial de las unidades geopedológicas presentes en la cuenca del río Ceibo, por ello se permite la representación cartográfica de la información para la gestión del riesgo u otras funciones a mencionar. Seguido a lo anterior, se plantea los siguientes objetivos para esta investigación:

Objetivo general

- Caracterizar la geopedología de la cuenca mediante el análisis geomorfológico y de suelos usando datos geoespaciales y e información disponible de estudios de suelo.

Objetivos específicos

- Clasificar formas, procesos y materiales geomorfológicos e hidroclimatológicos presentes con la interpretación de imágenes satelitales, datos mundiales y nacionales.
- Especificar los suelos existentes en la cuenca mediante la predicción obtenida de los tres modelos.
- Proponer las unidades geopedológicas de la cuenca por medio de la selección de los resultados según la estadística generada.

Justificación

La investigación en la región sur de Costa Rica es muy escasa, en especial en la temática geopedológica y temas cercanos a este desde la geografía. Debido a lo anterior, para el sector de la cuenca del río Ceibo, es fundamental conocer la dinámica debido a que la contribución de un conocimiento más profundo propicia la aplicación de prácticas en el espacio, un beneficio social y económico en efecto de una base teórica para el manejo del espacio.

La región sur de Costa Rica, a pesar de ser una de las más extensas y ricas en biodiversidad y recursos naturales, enfrenta una significativa carencia de análisis detallados sobre sus dinámicas geográficas (Quesada-Román et al., 2023). Esta falta de estudios no solo limita el conocimiento sobre la región, sino que también impide el desarrollo regional fundamentado en bases científicas. Las comunidades locales, al carecer de información precisa y detallada, se ven incapacitadas para abordar eficazmente los problemas emergentes y planificar su progreso de manera sostenible. La ausencia de datos geográficos detallados representa una barrera considerable para el desarrollo económico, social y ambiental de la zona.

La presente investigación busca llenar el vacío de conocimiento existente mediante un estudio geopedológico detallado, el cual proporcionará información crucial sobre las características del suelo y la topografía de la región. Este análisis no solo contribuirá al campo de la geografía y la geopedología, sino que también ofrecerá nuevas perspectivas para la planificación estratégica y el ordenamiento territorial en el cantón de Buenos Aires de Puntarenas, que actualmente carece de un plan regulador (Posada & Ramírez, 2015).

Los estudios geopedológicos tienen aplicaciones directas en la optimización del manejo territorial y la planificación espacial. La obtención de datos precisos facilitaría la creación de planes integrales de gestión en el distrito central de Buenos Aires, lo cual beneficiará a comunidades como Ujarrás y Ceibo al fomentar un uso sostenible de los recursos locales. Estos datos también son clave para formular políticas que equilibren el desarrollo económico y la conservación ambiental, reducen los impactos negativos potenciales en la zona.

La aplicación de estrategias basadas en estudios geopedológicos jugará un papel crucial en el desarrollo rural equitativo y sostenible de la región. Una comprensión detallada de la capacidad del suelo permitirá mejorar la productividad agrícola y las actividades económicas fundamentales, contribuyendo al bienestar de las comunidades locales a largo plazo.

Además, una visión integral del ordenamiento ambiental favorecerá la biodiversidad y el manejo adecuado de la cuenca del río Ceibo, mejorar la calidad de vida de los habitantes de la región.

Este estudio se destaca por su enfoque integral y multidimensional, aborda no solo la falta de datos geográficos, sino también su aplicación práctica en la planificación y el desarrollo regional. La originalidad del estudio radica en su capacidad para proporcionar una base de conocimiento que guíe la formulación de políticas territoriales y ambientales, facilita un desarrollo equilibrado y sostenible en una región que ha sido históricamente poco estudiada (Quesada-Román et al., 2023).

El potencial desarrollo de este estudio geopedológico resulta esencial para superar las limitaciones actuales y crear nuevas oportunidades de desarrollo sostenible dentro de la delimitación de la cuenca del río Ceibo. Al generar productos cartográficos detallados y ofrecer herramientas para una planificación estratégica efectiva, esta investigación puede transformar la forma en que las comunidades locales gestionan sus recursos y abordan los desafíos futuros, traza un camino hacia un desarrollo más equitativo y sostenible.

Definición y caracterización del área de estudio

La cuenca del río Ceibo, es un área de gran relevancia geográfica y ecológica, caracterizada por su diversidad biológica y su geomorfología compleja. Esta región se sitúa en un contexto tropical húmedo, lo que influye en sus patrones de precipitación, suelos y ecosistemas. La cuenca forma parte de la vertiente del Pacífico y está delimitada por la Cordillera de Talamanca al norte y el océano Pacífico al sur, lo que crea un entorno geográfico único y digno de un análisis exhaustivo (**Figura 1**).

Este sitio presenta un relieve variado que incluye llanuras, colinas y montañas. Las elevaciones en la región oscilan entre los 360 m y los 3250 m sobre el nivel del mar, con un predominio de pendientes moderadas a pronunciadas todo esto en una extensión de 299,72 km^2. La geomorfología de la cuenca ha sido influenciada por la actividad tectónica y volcánica de la región sobre todo en zonas cercanas a la Cordillera de Talamanca (Bergoeing, J. P. , 2012).

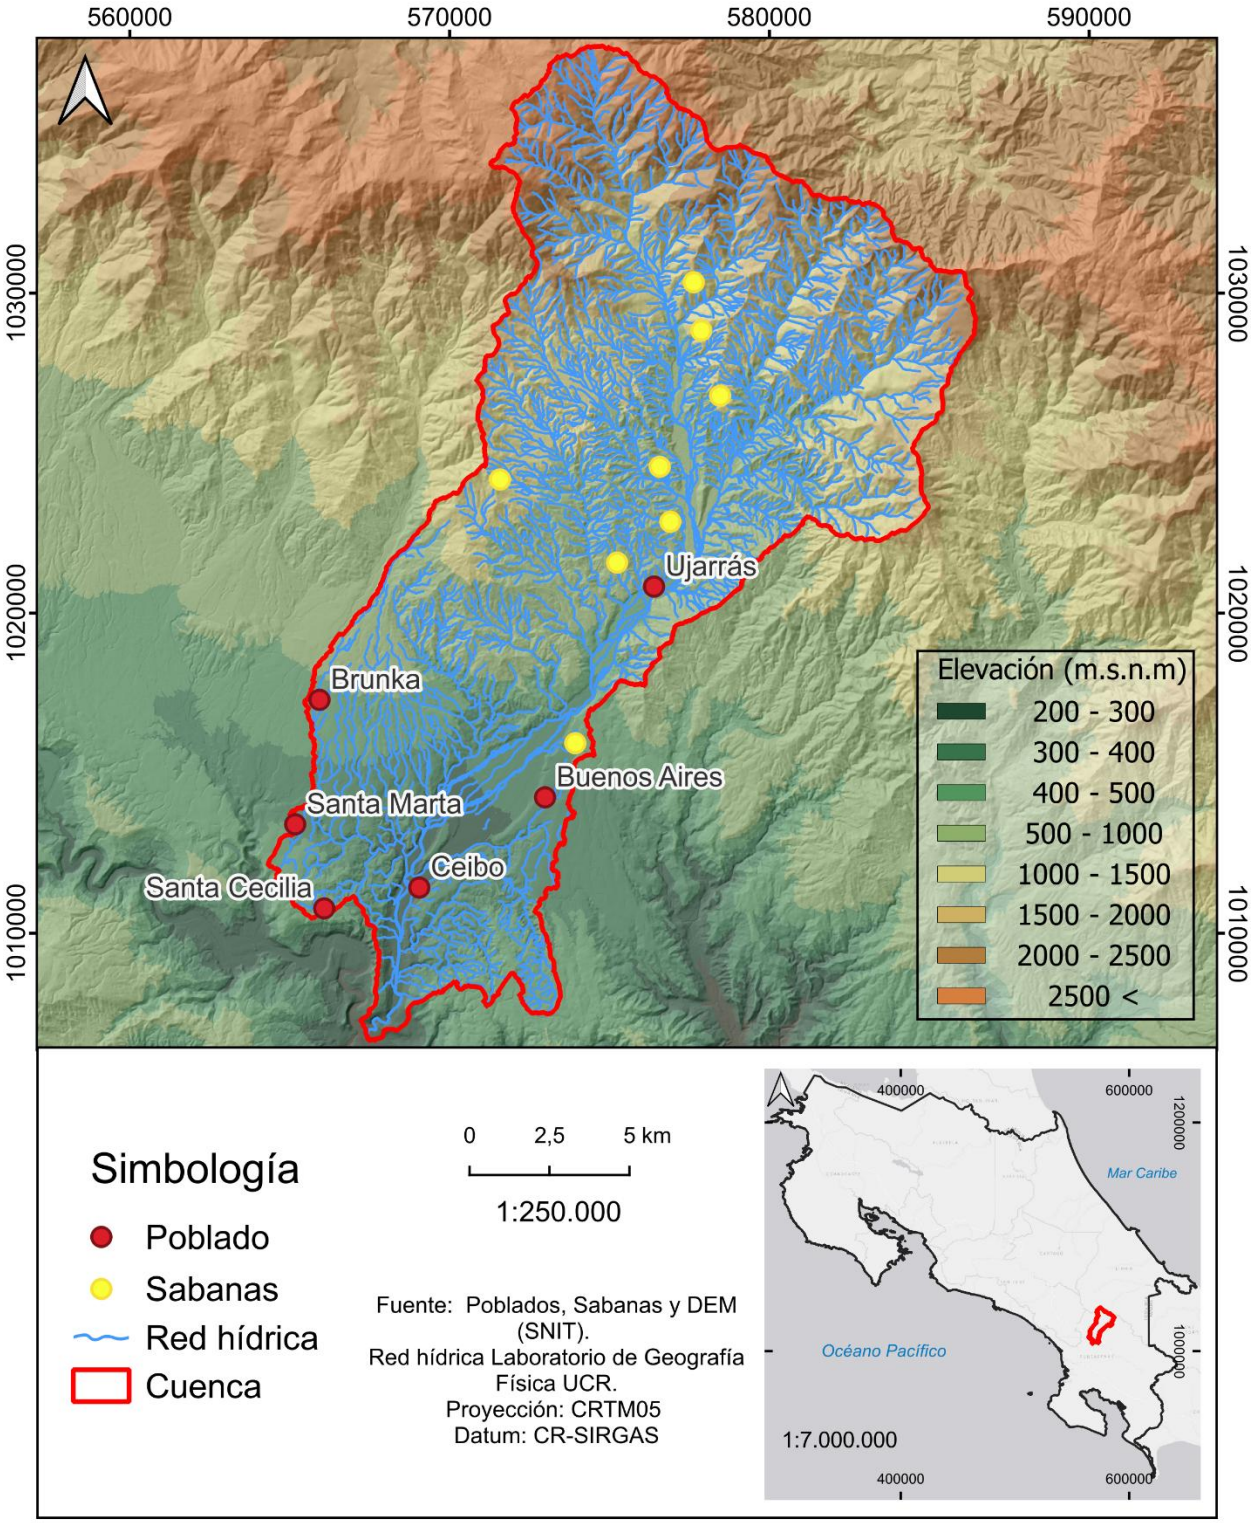

Figura 1. Localización de la cuenca del río Ceibo, Buenos Aires, Costa Rica. 2026.

Los suelos en esta cuenca son predominantemente Ultisoles y Oxisoles, caracterizados por sus elevados contenidos de arcilla, alta acidez y baja fertilidad natural, lo que presenta desafíos para la agricultura (Hughes et al., 2017; Camacho et al., 2021). Estos suelos son el resultado de procesos de meteorización prolongados, cuya configuración determina su capacidad para sustentar la vegetación. En sectores con cultivos de importancia se encuentran extensiones significativas de Oxisoles (Madrigal et al., 2022; Camacho et al., 2021). La cuenca del río Ceibo también tiene un impacto significativo en la economía local. La agricultura, en particular el cultivo de piña predomina en la actividad económica de la zona, junto con la ganadería, el café y la caña de azúcar (Camacho et al., 2024).

Esta cuenca se encuentra dominada principalmente por dos litologías: rocas intrusivas del Mioceno y depósitos aluviales del Cuaternario, de manera subordinada se observaron rocas sedimentarias del Mioceno y metamorfismo de contacto. En adición, las intrusiones se muestran con fuertes pendientes y ocupan la parte norte del área de estudio (Obando & Kussmaul, 2009).

El clima de la cuenca del río Ceibo es tropical húmedo, con dos estaciones bien definidas: una estación seca que se extiende de diciembre a abril y una estación lluviosa que abarca de mayo a noviembre. La precipitación anual promedio puede alcanzar hasta 3500 mm en los meses más lluviosos, especialmente en el mes de octubre que está asociado con los efectos de ciclones tropicales (Quesada-Román et al., 2024). Este régimen de lluvias genera un ambiente de alta humedad, lo que favorece la vegetación densa y la biodiversidad. Las temperaturas medias anuales oscilan entre 28 °C y 34 °C, contribuyendo a un microclima que varía según la altitud y la exposición al sol (solana y umbría). La variabilidad climática en esta región puede afectar drásticamente los patrones de escorrentía y el uso de recursos hídricos en las próximas décadas (IMN, 2023).

El río Ceibo es el principal cuerpo de agua de la cuenca, y su régimen hidrológico está estrechamente relacionado con las precipitaciones estacionales. Durante la estación lluviosa, el caudal del río puede aumentar significativamente, lo que puede generar inundaciones en las áreas adyacentes y planas (Programa Estado de la Nación, 2020). La cuenca también alberga una red de afluentes que contribuyen al drenaje y a la recarga de acuíferos locales, hacen de esta región importante para la agricultura y el abastecimiento de agua en la comunidad. La calidad del agua en la cuenca es un aspecto crucial que podría impactarse por las actividades agrícolas y ganaderas que se realizan en la zona.

La vegetación en la cuenca del río Ceibo es diversa, dominada por bosques húmedos tropicales y premontanos que albergan una amplia gama de especies de flora y fauna. Estos ecosistemas son cruciales para la conservación del suelo y la regulación del ciclo del agua, deempeñándose como un filtro natural que mejora la calidad del agua y reduce la erosión (Rojas et al., 2021). Sin embargo, se pueden encontrar ecosistemas de sabana en la parte alta de la cuenca las cuales son espacios con una afectación del fuego por su fácil combustión. Estos sitios se ven amenazados por la actividad humana que potencia este proceso. En la actualidad, se sigue sin ser identificado el origen de estas sabanas ya que se atribuyen a ser naturales, pero hay factores que lo señalan como creación de los pueblos originarios de la región (Artavia & Ávalos, 2020).

Metodología

Diseño del Estudio y Flujo de Trabajo

Los métodos aprendizaje automático (machine learning) es una rama de la inteligencia artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos sin ser explícitamente programados para ello (Mitchell, 1997). En el contexto del mapeo digital de suelos, el aprendizaje automático establece la relación entre variables ambientales observables (predictoras) y las propiedades del suelo medidas en campo (variable respuesta), para luego extrapolar esa relación al espacio continuo (McBratney et al., 2003). Dentro del aprendizaje automático supervisado, los métodos basados en árboles de decisión han mostrado consistentemente el mayor rendimiento en clasificación edáfica (Heung et al., 2016; Wadoux et al., 2020).

Por ello se utilizó de forma simultánea los métodos RF, XGBoost y CatBoost bajo el lenguaje de programación de Python usánndose como aplicativo el Visual Studio Code (desarrollado por Microsoft) ya que su interfaz facilita el manejo de datos y la modificación de los códigos para programar, el código a utilizar se encuentra en el repositorio propio de la investigación en la web de Github (Tencio, 2025). Para aprovechar las fortalezas complementarias de cada algoritmo y mitigar sus debilidades individuales. Random Forest proporciona una línea base robusta y es particularmente efectivo en conjuntos de datos con alta dimensionalidad, pero sin requerir ajuste fino de hiperparámetros. XGBoost, por su naturaleza secuencial, captura patrones sutiles y relaciones no lineales complejas, son especialmente útil en regiones de transición entre clases de suelos. CatBoost aporta robustez en el manejo de variables categóricas geológicas y geomorfológicas, reducen el riesgo de sobreajuste mediante su esquema de ordered boosting

(Wolpert, 1992; Dietterich, 2000). Las características de los métodos de análisis utilizados en la presente investigación se detallan en la **Tabla 1**.

Tabla 1. Comparación de las características de los algoritmos implementados

Característica	Random Forest	XGBoost	CatBoost
Estrategia de ensemble	Bagging (paralelo)	Boosting (secuencial)	Boosting (secuencial)
Riesgo de sobreajuste	Bajo	Medio-Alto	Bajo
Manejo de categóricas	Requiere codificación	Requiere codificación	Nativo
Velocidad de entrenamiento	Rápida	Muy rápida	Media
Interpretabilidad	Media (importancia de variables)	Media (SHAP values)	Alta (análisis de interacciones)
Regularización	Implícita (agregación)	Explícita (L1, L2)	Explícita (leaf-wise)

El ensemble learning (aprendizaje automático por conjuntos) es una estrategia de aprendizaje automático que combina múltiples modelos predictivos denominados weak learners (aprendices débiles) para producir un modelo final más robusto y preciso (Zhou, 2012). La premisa fundamental es que un conjunto de modelos diversos, aunque individualmente puedan tener limitaciones, pueden producir predicciones más confiables cuando se combinan adecuadamente (Dietterich, 2000). Esta diversidad entre modelos es esencial para el éxito del ensamblado, ya que modelos idénticos no aportan información nueva (Kuncheva & Whitaker, 2003). Bagging Booststrap Aggregating es una técnica de ensemble learning que entrena múltiples modelos de manera paralela e independiente, cada uno con una muestra diferente del conjunto de datos original generada mediante bootstrap (muestreo aleatorio con reemplazo) (Breiman, 2001).

La presente investigación se desarrolló mediante un flujo de trabajo sistemático que integra datos espaciales multifuente, técnicas de aprendizaje automático y validación cruzada rigurosa. El proceso completo se implementó en Python (Python Software Foundation, 2023) utiliza bibliotecas especializadas para análisis geoespacial GeoPandas (Jordahl et al., 2020); Rasterio (Gillies et al., 2013), aprendizaje automático (Random Forest, XGBoost, CatBoost) y manejo de datos NumPy (Harris et al., 2020) y Pandas (McKinney, 2010).

Los algoritmos de aprendizaje automático empleados se basan en teoría de ensemble learning y gradient boosting. Random Forest minimiza la varianza mediante agregación Bootstrap, la cual se detalla en la siguiente ecuación:

$$Var(\bar{E}) = Var(E)/n$$ **Ecuación 4**

Donde n es el número de árboles, $Var(\bar{E})$ corresponde a la varianza del error medio $Var(E)$ es la varianza del error individual del modelo (Breiman, 2001). Esta expresión indica que la varianza del error disminuye conforme aumenta el tamaño muestral, principio fundamental en métodos de ensamble y promediado de modelos, como los utilizados en Random Forest y boosting.

XGBoost optimiza una función objetivo regularizada:

$$L(\varphi) = \Sigma_i\, l(y_i, \hat{y}_i) + \Sigma_k\, \Omega(f_k)$$ **Ecuación 5**

Donde $L(\varphi)$ es la función de pérdida y Ω penaliza la complejidad del modelo, $\mathbf{l(y_i, \hat{y}_i)}$ representa la función de pérdida asociada a la diferencia entre la clase observada $\mathbf{y_i}$ y la clase predicha $\mathbf{\hat{y}_i}$ para la observación i. Además, f_k corresponde a cada uno de los árboles individuales que componen el modelo, i y k son índices de observaciones y árboles, respectivamente. Esta formulación es característica de algoritmos de *gradient boosting*, donde se busca minimizar simultáneamente el error de predicción y la complejidad del modelo. Zhang et al., (2021), aplicaron exitosamente extreme gradient boosting en la predicción de propiedades geotécnicas de suelos.

CatBoost implementa ordered boosting que reduce prediction shift mediante la siguiente función:

$$\hat{y}_k = F_{k-1}(x_i)$$ **Ecuación 6**

Donde $\hat{y}_k$ *es* la predicción en la iteración k. $F_{k-1}(x_i)$ corresponde al modelo acumulado hasta la iteración anterior aplicado a la observación i, x_i es el vector de variables predictoras ambientales asociado a la observación i (Prokhorenkova et al., 2018). Estos métodos han sido ampliamente validados en pedometría digital por Hengl et al., (2017) y Wadoux et al., (2019).

Datos de Entrada y Preprocesamiento

Datos de Entrenamiento

Se utilizaron 1 243 perfiles del suelo (Mata et al., 2013) georreferenciadas distribuidas en la cuenca del Río General provenientes de la página oficial del Centro de Investigaciones Agronómicas de la UCR (CIA), clasificadas según el sistema de Taxonomía de Suelos del USDA (Soil Survey Staff, 2014). Previo al modelado, se realizó una limpieza de datos que eliminó 1 observación con valor nulo en la clasificación taxonómica. Se asignó un identificador único a cada muestra para garantizar trazabilidad y prevenir pérdida de información durante la partición de datos.

Variables Ambientales Predictoras

Se compilaron 11 variables ambientales (**Tabla 2**) espacialmente explícitas que representan los factores formadores de suelos según el modelo CLORPT, un modelo conceptual que establece que las propiedades del suelo son función de cinco factores formadores, expresado matemáticamente como según la siguiente función:

$$S = f(cl, o, r, p, t)$$ **Ecuación 7**

Cada una de estas letras son (Climate, Organisms, Relief, Parent material, Time), formalizadas por Hans Jenny (1941), donde S representa las propiedades del suelo (**Ecuación 7**). Es importante señalar que el propio Jenny reconoció explícitamente que esta ecuación es una aproximación conceptual a la realidad, no una relación funcional estricta, ya que en la práctica los factores formadores no actúan de forma independiente sino en interacción constante; así, el clima influye sobre la vegetación, la vegetación sobre el material parental y el relieve sobre el clima local (Jenny, 1941). Esta limitación inherente al modelo justifica el uso de algoritmos de aprendizaje automático, capaces de capturar interacciones no lineales entre factores que no pueden ser representadas analíticamente por la ecuación de Jenny (McBratney et al., 2003; Minasny et al., 2024). Todas las capas raster se estandarizaron a una resolución de 30 m y se reproyectaron al sistema de coordenadas UTM Zona 17N (EPSG:32617) para minimizar distorsiones geométricas.

La clasificación geomorfológica se aborda a partir de tres componentes fundamentales: formas del relieve, identificadas mediante geomorfometría automatizada (geomorfones); procesos geomorfológicos dominantes, inferidos mediante la topografía, la pendiente y la dinámica hidrológica; y materiales geomorfológicos, representados por la litología y los depósitos

superficiales. Esta clasificación permite vincular directamente las características del relieve con los procesos de formación de suelos, en concordancia con el enfoque geopedológico.

Partición de Datos y Estrategia de Validación

Los datos se dividieron en conjuntos de entrenamiento (70%, *n*=871) y prueba (30%, *n*=372) mediante muestreo estratificado que preservó la proporción de clases en ambos subconjuntos. Se empleó una estrategia adaptativa para manejar clases con muy pocas observaciones: las clases con menos de 4 muestras (Histosoles, n=3) se asignaron completamente al conjunto de entrenamiento para permitir el aprendizaje del modelo, mientras que las clases mayoritarias se dividieron estratificadamente con train_test_split (función de la biblioteca scikit-learn de Python que divide aleatoriamente un dataset en conjuntos de entrenamiento y prueba, permiten evaluar el rendimiento del modelo en datos no vistos) siguen los lineamientos de Pedregosa et al., (2011) con semilla aleatoria fija (random_state=42) para garantizar reproducibilidad. Se implementó un sistema de verificación de integridad que confirmó la ausencia de intersección entre conjuntos mediante comparación de identificadores únicos (unique_id). Esta validación es estrictamente necesaria para prevenir fuga de datos, que inflaría artificialmente las métricas de desempeño (Kaufman et al., 2012). El conjunto de prueba se mantuvo completamente aislado hasta la evaluación final del modelo (**Tabla 2**).

Tabla 2. Partición de muestras utilizadas para los 3 modelos.

Orden de Suelo	Total	Entrenamiento (70%)	Prueba (30%)
Alfisoles	39	27	12
Andisoles	130	91	39
Entisoles	67	47	20
Inceptisoles	247	173	74
Mollisoles	6	4	2
Histosoles	3	3	3
Oxisoles	81	57	24
Ultisoles	670	469	201
Total	1243	871	372

Extracción de Características Espaciales

Para cada punto de muestreo, se extrajeron valores de las 11 variables ambientales (**Tabla 3**) mediante muestreo puntual de las capas raster. El resultado fue una matriz de características denominadas Xtrain (871 × 11 para el entrenamiento) y Xtest (372 × 11 para la validación), junto con sus vectores de etiquetas correspondientes ytrain y ytest.

Se verificó la independencia de los conjuntos se compara las primeras tres características de cada matriz, confirma que no existían filas idénticas entre Xtrain y Xtest. (Esta verificación se realizó mediante comparación elemento a elemento de las columnas de elevación, temperatura máxima y pendiente entre ambos conjuntos, se utiliza la función pandas.DataFrame.isin() para identificar registros duplicados. Se confirmó que ninguna fila del conjunto de entrenamiento aparecía en el conjunto de prueba, garantiza así la validez de la evaluación del modelo al evitar fuga de información, según las recomendaciones de validación cruzada de Hastie et al., (2009). Las etiquetas categóricas de órdenes de suelos se codificaron numéricamente mediante LabelEncoder, preserva la coherencia en la transformación para garantizar la correcta interpretación de predicciones.

Tabla 3. Variables utilizadas para la predicción.

Grupo de variables	Variable	Descripción / Fuente
Topográficas	DEM (Modelo Digital de Elevación)	Derivado de SRTM 30 m, rango altitudinal 360–3,250 msnm
Topográficas	Pendiente	Calculada a partir del DEM mediante algoritmo D8, expresada en grados (0–90°)
Topográficas	Rugosidad	Índice de Rugosidad del Terreno (TRI) según Riley et al. (1999)
Topográficas	Sombreado (Hillshade)	Iluminación teórica con azimut 315° y altitud solar 45°
Topográficas	Geomorfometría	Clasificación de 10 formas de relieve mediante el índice Geomorphons Jasiewicz y Stepinski (2013)
Climáticas	Temperatura máxima	Promedio anual 2000–2020, datos CHIRTS Funk et al. (2015)
Climáticas	Precipitación	Promedio anual 2000–2020, datos CHIRPS Funk et al. (2019)
Temáticas	Geología	Mapa litológico 1:50,000 del Mapa Geológico de Costa Rica, 8 unidades principales, Denyer et al. (2014)
Temáticas	Geomorfología	Unidades del paisaje, escala 1:25,000, 12 clases
Temáticas	Uso del suelo	Clasificación supervisada Sentinel-2 (2022), 15 clases, FAO (2022) Tabla 2b.

Temáticas	NDVI	Índice de Vegetación de Diferencia Normalizada, promedio anual derivado de Sentinel-2

Tabla 3b. Clases utilizadas en la variable de Uso del suelo según FAO (2022).

Código	Categoría	Descripción
1	Bosque denso	Cobertura arbórea cerrada, bosque húmedo tropical y premontano
2	Sabana / Pastos naturales	Formaciones herbáceas con cobertura arbórea dispersa, Valle del General
3	Pastos cultivados / Agropecuario	Ganadería extensiva y cultivos permanentes
4	Cultivos anuales	Agricultura de subsistencia y comercial
5	Vegetación secundaria	Rastrojos y áreas en regeneración
6	Suelo desnudo / Afloramientos	Áreas sin cobertura vegetal, cauces activos
7	Agua	Ríos, quebradas y cuerpos lénticos

Para estas variables utilizadas, una vez cargados los rásters se empleó el método de resampleo bilineal mediante la función reproject de la librería rasterio (Gillies et al., 2013), aplicado de manera uniforme a todas las variables, tanto continuas como categóricas. Se reconoce que para variables categóricas (Geología, Geomorfología, Uso de la Tierra) el método óptimo sería el vecino más cercano (nearest neighbor), que preserva los valores discretos originales sin introducir valores intermedios inexistentes; sin embargo, dado que la reproyección se realizó entre sistemas de coordenadas con diferencias angulares menores, el impacto práctico sobre las categorías es mínimo (Hengl et al., 2017; Gillies et al., 2013).

Configuración y Entrenamiento de Modelos

Se implementaron tres estrategias diferenciadas de modelado para maximizar la diversidad y explotar las fortalezas complementarias de cada algoritmo. La configuración de hiperparámetros se optimizó mediante validación cruzada de 5 pliegues en un subconjunto de datos, prioriza el balance entre capacidad predictiva y generalización.

El modelo Random Forest (RF) se configuró con enfoque conservador para maximizar estabilidad y reducir varianza. En ese sentido, se ajustaron 150 árboles (n_estimators=150), con una profundidad máxima de 15 niveles (max_depth=15), un mínimo de 10 muestras para división (min_samples_split=10) y 4 muestras para hojas terminales (min_samples_leaf=4). Críticamente, se limitó el muestreo al 70% de los datos por árbol (max_samples=0.7) y se utilizó solo $\sqrt{11} \approx 3$

características por división (max_features='sqrt') este número mecionado hace referencia a que de las 11 variables se escoge de forma aleatoria 3 para cada árbol construido en el modelo son así diferente en cada árbol nuevo , fuerza la diversidad entre árboles y reduce la correlación. Se aplicó ponderación de clases (class_weight='balanced') para compensar el desbalance del dataset.

XGBoost se configuró con una estrategia "agresiva" prioriza la capacidad de aprendizaje mediante muchos árboles pequeños, es decir 300 rondas de boosting (n_estimators=300), profundidad limitada a 6 niveles (max_depth=6) y una tasa de aprendizaje muy conservadora (learning_rate=0.03) que permite actualizaciones graduales del modelo. Se implementó submuestreo agresivo con 80% de observaciones (subsample=0.8), con un 80% de características por árbol (colsample_bytree=0.8) y por nivel (colsample_bylevel=0.8). La regularización L1 y L2 (reg_alpha=1.0, reg_lambda=2.0) penaliza la complejidad del modelo, previene sobreajuste especialmente en clases minoritarias.

CatBoost se implementó con configuración balanceada que aprovecha su capacidad de manejo nativo de variables categóricas, con 200 iteraciones (iterations=200), una profundidad media-alta de 8 niveles (depth=8) y tasa de aprendizaje de 0.05 (learning_rate=0.05). Se implementó una regularización L2 fuerte (l2_leaf_reg=10) que controla la complejidad de las hojas, mientras que el parámetro de fuerza aleatoria (random_strength=2.0) introduce aleatoriedad en las divisiones para mejorar generalización. Se utilizó bootstrap tipo Bernoulli (bootstrap_type='Bernoulli') con 75% de muestreo (subsample=0.75) para prevenir sobreajuste mediante un enfoque de "ordered boosting".

La configuración diferenciada de hiperparámetros y semillas aleatorias dentro de los algoritmos (RF: 42, XGBoost: 123, CatBoost: 456) garantiza que los modelos exploren diferentes regiones del espacio de hipótesis, captura complementariamente patrones en los datos. Esta diversidad es fundamental para correcto resultado, ya que modelos idénticos no aportan información nueva (Kuncheva & Whitaker, 2003).

El uso de diferentes semillas aleatorias genera diversidad necesaria en ensemble learning, lo cual ha sido validado por Zhou, (2012) quien demostró que la diversidad entre modelos base mejora significativamente el rendimiento del ensemble. Además, Dietterich, (2000) estableció que la variación en la inicialización de modelos es una de las tres fuentes principales de diversidad en ensemble methods, junto con el uso de diferentes algoritmos y diferentes conjuntos de entrenamiento.

Si bien el objetivo central del estudio es la cuenca del río Ceibo, los modelos predictivos se entrenaron y aplicaron sobre la cuenca del río General con el fin de maximizar la diversidad ambiental y el número de observaciones disponibles en las cuales se tiene un total 1243 perfiles como ya se han mencionado. La mayor densidad de perfiles de suelo en la cuenca del río General permite mejorar la capacidad de generalización de los modelos y reducir la incertidumbre asociada a la predicción en subcuencas con menor densidad de datos, como el río Ceibo (con solo 86 perfiles de suelo). De esta forma, la cuenca del Ceibo se analiza como una unidad espacial específica dentro de un marco regional más amplio.

Predicción Espacial y Generación de Mapas de suelos

Específicamente, la predicción se extendió a toda la cuenca del río General como se mencionó con anterioridad, que el río Ceibo es una subcuenca de esta, permitió capturar la variabilidad ambiental completa del sistema hidrográfico regional, esto para magnificar la diversidad de variables y así los modelos encuentren similitudes en diferentes espacios para la integración de la predicción. El área de estudio se configuró como un ráster de 4 637 × 3 595 píxeles (con resolución de 30 m = 1 pixel), representa 6 653 165 píxeles válidos dentro de la máscara de la cuenca la cual tiene una extensión de 5987.85 km². Cada píxel adquiere la información inferida por el modelo, mediante el valor de entrenamiento y las variables similares presentes en cada valor de perfil de suelo. Los tres modelos entrenados se aplicaron independientemente, que genera tres rásters de clasificación espacial los cuales posteriormente se ven reproyectados para generar la correcta representación cartográfica.

Para el proceso de creación cartográfica se toma como herramienta SIG el QGIS (software libre de SIG, desarrollado por la comunidad QGIS y basado en Python), en este software existe la funcionalidad de observas los resultados obtenidos y además la creación de una cartografía personalizada.

Métricas de Evaluación del Desempeño

El desempeño de los modelos se evaluó mediante un conjunto comprehensivo de métricas que caracterizan diferentes aspectos de la capacidad predictiva, estas métricas se incluyen en el código creado en el lenguaje de Python, a continuación, se presentan las formas de evaluación del desempeño integradas:

- Exactitud global (Overall Accuracy, OA):

Proporción de predicciones correctas sobre el total de observaciones. La exactitud global es una de las métricas más utilizadas en clasificación temática, aunque presenta limitaciones en contextos con desbalance de clases (Congalton, 1991; Foody, 2002).

$$OA = (TP + TN) / N$$ **Ecuación 8**

Donde *OA* es la exactitud global del modelo. *TP* son verdaderos positivos (predicciones correctas de la clase positiva), TN son verdaderos negativos (predicciones correctas de la clase negativa), y *N* es el tamaño total del conjunto de prueba.

- Coeficiente Kappa de Cohen (κ):

Mide el acuerdo entre predicciones y observaciones que se ajustan por concordancia esperada por efecto aleatorio. El coeficiente Kappa de Cohen permite evaluar el grado de concordancia ajustado por azar (Cohen, 1960), es interpretado comúnmente según la escala de Landis y Koch (1977) definida de la siguiente forma:

$$\kappa = (p_0 - p_e) / (1 - p_e)$$ **Ecuación 9**

Donde κ es el coeficiente Kappa de Cohen, p_0 es la exactitud observada y p_e es la exactitud esperada por el efecto aleatorio, calculada mediante la siguiente función:

$$p_e = \Sigma_i (n_{i+} \cdot n_{+i}) / N^2$$ **Ecuación 10**

donde n_{i+} es el total de observaciones reales de la clase *i* y n_{+i} es el total de predicciones asignadas a la clase *i* en la matriz de confusión. Los valores del coeficiente de Kappa de Cohen se pueden interpretar mediante la siguiente categorización de acuerdo con Landis & Koch (1977):

- κ menor a 0,40: Desempeño pobre del modelo.
- 0,40-0,60: Desempeño moderado del modelo.
- 0,60-0,80: Desempeño sustancial del modelo.
- mayor a 0,80: Desempeño alto del modelo.
-

El coeficiente Kappa de Cohen mide el acuerdo entre las predicciones del modelo y las observaciones reales, corrigiendo la concordancia que podría ocurrir por puro azar. En el contexto de la clasificación de suelos, el 'acuerdo esperado por azar' (pe) representa la proporción de predicciones que serían correctas si el modelo asignara clases aleatoriamente, siguiendo únicamente la distribución de frecuencias de cada clase. Dicho de otro modo, si una clase de suelo representa el 60% de las muestras, un clasificador aleatorio acertaría ese 60% de los casos simplemente por probabilidad, sin ningún aprendizaje real. El coeficiente κ penaliza ese acierto fortuito y cuantifica únicamente la capacidad discriminativa genuina del modelo (Cohen, 1960; Congalton, 1991). Por esta razón, κ es particularmente informativo en conjuntos de datos desbalanceados, donde la exactitud global puede ser engañosamente alta.

- F1-Score ponderado:

Este parámetro representa la media armónica de precisión y exhaustividad, ponderada por el soporte de cada clase. Es especialmente relevante en conjuntos desbalanceados, y penaliza modelos con buen desempeño solo en clases mayoritarias (Powers, 2011; Saito & Rehmsmeier, 2015). Dicho parámetro se estima mediante la siguiente ecuación:

$$F1_i = 2 \cdot (Precisión \cdot Recall) / (Precisión + Recall)$$ **Ecuación 11**

En ese sentido *Precision* es la precisión de la clase *i* y *Recall* es la exhaustividad de la clase *i*, $F1_i$ es calculado con las funciones:

$$\text{Precisión} = TP / (TP + FP)$$ **Ecuación 12**

$$\text{Recall} = TP / (TP + FN)$$ **Ecuación 13**

Donde TP son verdaderos positivos (predicciones correctas de la clase positiva), TN son verdaderos negativos (predicciones correctas de la clase negativa), FP son los valores falsos positivos (predicciones incorrectas de la clase positiva).

El F1 ponderado ($F1_{pon}$) se calcula como mediante la siguiente ecuación:

$$F1_{pon} = \Sigma_i (w_i \cdot F1_i) \quad \textbf{Ecuación 14}$$

Donde $F1_i$ es el F1-score de la clase i y w_i es el peso de cada clase según su frecuencia, calculado de la siguiente manera:

$$w_i = n_i / N \quad \textbf{Ecuación 15}$$

Donde n_i es la clase específica i, y N representa la cantidad total de clases.

- F1-Score macro:

Este parámetro constituye un promedio simple de F1-Score por clase, el cual brinda igualdad de importancia a todas las clases independientemente de su frecuencia. Es muy útil para identificar modelos que descuidan clases minoritarias (He & Garcia, 2009; Hengl et al., 2017). El cómputo de este parámetro se realiza de a siguiente forma:

$$F1_{macro} = (1/C) \cdot \Sigma_i F1_i \quad \textbf{Ecuación 16}$$

Donde C es el número de clases. A diferencia del F1 ponderado, esta métrica no considera la frecuencia de cada clase, dan el mismo peso a clases raras y comunes.

- Matriz de confusión:

En este parámetro, se confecciona una tabla de contingencia que muestra la distribución de clasificaciones correctas e incorrectas por clase, permite identificar patrones de confusión específicos entre órdenes de suelos similares.

Se calculó el grado de sobreajuste como la diferencia entre la exactitud en entrenamiento y prueba mediante la siguiente fórmula:

$$\Delta = OAtrain - Oatest \quad \textbf{Ecuación 17}$$

Donde OAtrain es el nivel de exactitud del modelo de entrenamiento, y OAtest es el nivel de exactitud del modelo con datos de validación.

Los valores de Δ menores a 0,05 indican un buen balance sesgo-varianza, mientras que $\Delta >$ 0,10 sugieren sobreajuste problemático (Hastie et al., 2009). Todas las métricas se calcularon sobre el conjunto de prueba independiente, esto para así ver cuál de los tres modelos ejecutados en el proceso tiene un mejor acercamiento con los datos más allá de un resultado visual armonioso.

Todas estas métricas de evaluación se ejecutan en el mismo código diseñado en el lenguaje de Python, la librería integrada del lenguaje denominada scikit-learn facilita la creación de estos datos para la evaluación del desempeño de cada modelo utilizado de forma individual y comparativa.

RESULTADOS

Desempeño Comparativo de los Modelos de Clasificación para el Mapeo Digital de Suelos

Los tres modelos de aprendizaje automático evaluados en la presente investigación mostraron alto desempeño en la clasificación de órdenes de suelos, aunque con diferencias notables en su capacidad predictiva y grado de ajuste. La **Tabla 4** resume los parámetros de evaluación del desempeño de los modelos obtenidos en los conjuntos de entrenamiento y prueba para cada algoritmo.

Tabla 4. Parámetros de desempeño de los modelos de predicción empleados para el mapeo digital de suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica.

Modelo	OA Train	OA Test	Kappa Test	F1-Weighted	Overfitting
Random Forest	0,967	**0,919**	0,876	0,919	0,047
XGBoost	**0,991**	**0,962**	**0,941**	**0,959**	**0,028**
CatBoost	0,917	0,866	0,776	0,851	0,052

Nota: OA = Overall Accuracy (Exactitud Global). Valores en negrita indican el mejor desempeño en cada métrica. Fuente: Elaboración propia.

El modelo XGBoost demostró ser el modelo con el mayor desempeño en la predcción, alcanza un valor de exactitud global de 96,2% en el conjunto de prueba y un coeficiente Kappa de 0,941, que según la escala de Landis & Koch (1977) corresponde a un nivel de concordancia de nivel alto. Este resultado superior se podría atribuir a la capacidad del algoritmo de construir secuencialmente árboles que corrigen progresivamente los errores de iteraciones previas, capturan patrones complejos y no lineales en las relaciones suelo-paisaje. Notablemente, el modelo mostró un bajo grado de sobreajuste (2,8%), indican excelente capacidad de generalización a datos no vistos durante el entrenamiento.

El análisis detallado por clases (**Tabla 5**) reveló que XGBoost alcanzó precisión elevada (1,000) en cuatro de los siete órdenes presentes en el conjunto de prueba: Alfisoles, Andisoles, Inceptisoles y Oxisoles. El único orden con un desempeño considerado como moderado fue el de los Entisoles (F1-score = 0,889), donde la exhaustividad de 0,80 indica que 20% de los Entisoles fueron clasificados erróneamente, probablemente dentro del orden de los Inceptisoles. El modelo no logró clasificar de forma correcta ninguna muestra de Mollisoles (n=2 en test), donde este orden de suelos representó solo 0,5% del total de datos evaluados.

Tabla 5. Desempeño en la predicción por orden de suelo mediante el Modelo XGBoost para el mapeo digital de suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica.

Orden de Suelo	Precisión	Exhaustividad	F1-Score	Soporte
Alfisoles	1,000	1,000	1,000	12
Andisoles	1,000	1,000	1,000	39
Entisoles	1,000	0,800	0,889	20
Inceptisoles	0,944	0,919	0,932	74
Mollisoles	0,000	0,000	0,000	2
Oxisoles	1,000	0,917	0,957	24
Ultisoles	0,953	1,000	0,976	201

El enfoque de Random Forest (RF) ocupó una posición intermedia con exactitud global de 91,9% y Kappa de 0,876 (concordancia de nivel alto). Aunque su desempeño fue 4,3 puntos porcentuales inferior a XGBoost, RF demostró mayor estabilidad evidenciada por un sobreajuste ligeramente superior (4,7%) pero aún dentro de rangos aceptables (**Tabla 6**). Esta robustez podría derviar de la naturaleza del algoritmo de bagging, donde la agregación de múltiples árboles independientes reduce la varianza del modelo final.

Tabla 6. Desempeño en la predicción por orden de suelo mediante el Modelo Random Forest (RF) para el mapeo digital de suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica.

Orden de Suelo	Precisión	Exhaustividad	F1-Score	Soporte
Alfisols	1,000	1,000	1,000	12
Andisols	0,907	1,000	0,951	39
Entisols	0,850	0,850	0,850	20
Inceptisols	0,897	0,824	0,859	74
Mollisols	1,000	1,000	1,000	2
Oxisols	0,880	0,917	0,898	24
Ultisols	0,936	0,940	0,938	201

El patrón de errores de RF difiere notablemente de XGBoost. Mientras que RF alcanzó precisión considerable en Alfisoles, Andisoles y Mollisoles, mostró mayor confusión en Entisoles (exhaustividad = 0,85) e Inceptisoles (precisión = 0,897). Este comportamiento sugiere que la estrategia conservadora implementada (max_samples=0,7, max_features='sqrt') efectivamente previno sobreajuste, pero a costa de menor capacidad para capturar patrones sutiles en clases con alta variabilidad interna.

Finalmente, el modelo CatBoost presentó el desempeño más conservador con exactitud de 86,6% y Kappa de 0,776 (**Tabla 7**). Este resultado inferior se explica por la fuerte regularización implementada (l2_leaf_reg=10), que efectivamente previno sobreajuste (5,2%) pero limitó la capacidad del modelo de ajustarse a patrones complejos. El análisis por clases reveló dificultades particulares en órdenes de suelo menos frecuentes en la cuenca, por ejemplo, el orden de los Entisoles mostró exhaustividad de solo 0.35, indica que el 65% de estos suelos fueron erróneamente clasificados, principalmente como Ultisoles o Inceptisoles.

Paradójicamente, CatBoost alcanzó precisión considerable (1,000) en Alfisoles, Entisoles (cuando sí los identificó) y Oxisoles, sugiere que el modelo es altamente conservador en sus predicciones positivas, pero sacrifica la exhaustividad. Este comportamiento es característico de algoritmos con fuerte penalización de complejidad, que priorizan evitar falsos positivos sobre maximizar la detección de todas las instancias verdaderas.

Tabla 7. Desempeño en la predicción por orden de suelo mediante el Modelo CatBoost para el mapeo digital de suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica.

Orden de Suelo	Precisión	Exhaustividad	F1-Score	Soporte
Alfisols	1,000	0,500	0,667	12
Andisols	0,975	1,000	0,987	39
Entisols	1,000	0,350	0,519	20
Inceptisols	0,867	0,703	0,776	74
Mollisols	0,000	0,000	0,000	2
Oxisols	1,000	0,708	0,829	24
Ultisols	0,831	1,000	0,907	201

Importancia Relativa de Variables Ambientales en los Modelos de Clasificación

El análisis de importancia de variables reveló patrones consistentes entre los tres modelos evaluados, aunque con diferencias en el orden jerárquico que reflejan los distintos mecanismos de aprendizaje de cada algoritmo. La **Tabla 8** presenta las cinco variables más importantes para cada modelo, junto con sus valores de importancia normalizada.

Tabla 8. Resumen de las 5 variables de entrada de mayor importancia, utilizadas en cada modelo evaluado en el mapeo digital de suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica.

Ranking	Random Forest	XGBoost	CatBoost
1	DEM (0,196)	TempMax (0,170)	NDVI (12,52)
2	TempMax (0,162)	DEM (0,125)	Geomorph (12,48)
3	Hillshade (0,094)	Geología (0,105)	DEM (9,94)
4	Rugosidad (0,088)	Geomorph (0,099)	TempMax (9,89)
5	Pendiente (0,087)	Pendiente (0,088)	Hillshade (9,86)

*CatBoost usa escala diferente debido a su método de cálculo propietario.

La elevación (DEM) y temperatura máxima emergieron como los predictores más importantes en RF y XGBoost, reflejan el fuerte control que la altitud ejerce sobre la temperatura y la humedad, lo que de manera consecuentemente afecta sobre los procesos de meteorización y formación de suelos. Esta observación es consistente con el modelo de zonación altitudinal de suelos característico de regiones montañosas tropicales (Sarmiento, 1986). El rango altitudinal de la cuenca (360 - 3250 msnm) genera gradientes térmicos pronunciados que resultan en cambios pedogenéticos sistemáticos: Andisoles que predominan en elevaciones superiores a 2000 m con temperaturas bajas, mientras que los Ultisoles (suelos altamente meteorizados) dominan las tierras bajas cálidas y húmedas (<500 msnm).

La inclusión de variables topográficas secundarias (rugosidad, pendiente, hillshade) en las principales variables para RF sugiere que este algoritmo captura efectivamente la influencia de la morfología del terreno sobre procesos de redistribución de agua y sedimentos. La pendiente, controla la erosión diferencial y el espesor de horizontes, es un predictor clave para distinguir Entisoles (suelos con escaso desarrollo pedogenético en pendientes fuertes) de Inceptisoles y Ultisoles, perfiles con desarrollo pedogenético moderado a fuerte, respectivamente, en pendientes suavizadas.

EL modelo de XGBoost asignó mayor importancia a variables consideradas como categóricas (por ejemplo, Geología, Geomorfología) en comparación con RF, ocupan posiciones 3 y 4 respectivamente. Este resultado refleja la capacidad superior de los algoritmos de gradient boosting para manejar interacciones complejas entre variables continuas y categóricas. La geología, que representa el material parental, es un factor formador fundamental según el modelo CLORPT (Jenny, 1941), explica gran parte de la variabilidad mineralógica y química que distingue órdenes como Andisoles (suelos recientes, derivados de cenizas volcánicas) de Oxisoles (suelos altamente meteorizados derivados de antiguos abanicos aluviales).

La geomorfología, que integra información sobre formas del relieve y procesos superficiales, resultó particularmente relevante para separar Histosols (suelos orgánicos en depresiones mal drenadas) de órdenes de suelos de origen mineral. Sin embargo, su importancia moderada (cuarta posición) sugiere que las variables topográficas continuas (DEM, pendiente) ya capturan gran parte de la información geomorfométrica relevante para clasificar los suelos.

CatBoost mostró un resultado diferente, prioriza NDVI y Geomorphons (clasificación de formas de relieve) sobre variables directamente topoclimáticas. Esta divergencia podría explicarse por dos factores: 1) el método de cálculo de importancia de CatBoost (basado en cambios de pérdida durante el entrenamiento), el cual difiere fundamentalmente de la reducción de impureza usada por RF o XGBoost, y 2) la fuerte regularización implementada pudo haber forzado al modelo a buscar señales en variables menos correlacionadas entre sí. El NDVI, como proxy de cobertura vegetal y actividad biológica, captura indirectamente efectos de temperatura, humedad y propiedades del suelo sobre el crecimiento vegetal, que funciona como variable integradora.

Es notable que variables esperadamente importantes como precipitación y uso de suelo no aparecieron en los 5 factores principales de ningún modelo. Esto sugiere que: 1) su variabilidad espacial es mayormente explicada por elevación y temperatura (colinealidad), o 2) su influencia sobre la distribución de órdenes de suelos es secundaria comparada con el control topográfico-térmico en esta región montañosa tropical.

Distribución Espacial de Clases de Suelos y Cartografía Digital

Los tres modelos generaron mapas de clasificación con 6,653,165 píxeles válidos (resolución 30 m) que cubre 5987,85 km² que como se mencionó en el apartado de Predicción y Generación de mapas, se hace con un área correspondiente a la cuenca del río General. La **Tabla 9** presenta la distribución espacial de órdenes de suelos según cada modelo, expresada en área y porcentaje de cobertura.

Tabla 9. Cobertura espacial de órdenes de suelo por modelo evaluado (después de suavizado) en el mapeo digital de suelos en la cuenca del Río General, Costa Rica.

Orden	RF (km²)	RF (%)	XGB (km²)	XGB (%)	CAT (km²)	CAT (%)
Ultisoles	4036,02	67,4	3363,79	56,2	4327,02	72,3
Andisoles	864,93	14,4	1229,29	20,5	982,68	16,4
Inceptisoles	685,60	11,5	1043,30	17,4	418,41	7,0
Entisoles	323,75	5,4	153,59	2,6	223,24	3,7
Histosoles	37,40	0,6	88,08	1,5	2,17	0,04
Oxisoles	25,44	0,4	81,53	1,4	29,58	0,5
Alfisoles	14,71	0,2	25,74	0,4	4,74	0,08
Mollisoles	0,00	0,0	2,79	0,05	0,00	0,0

Los tres modelos coincidieron en identificar a los Ultisoles como el orden dominante, que cubre entre 56,2% (XGBoost) y 72,3% (CatBoost) de la cuenca. Esta predicción es consistente con la distribución observada en el conjunto de entrenamiento (53,9%), valida que los modelos han aprendido correctamente el patrón mayoritario. La prevalencia de Ultisoles refleja las condiciones ambientales características de la región: altas temperaturas, precipitación abundante (>2500 mm año) y relieve ondulado que promueve mecanismos de meteorización intensa y lixiviación de bases, resulta en suelos ácidos y altamente meteorizados característicos de climas tropicales húmedos (Soil Survey Staff, 2014).

Sin embargo, la variabilidad de 16,1 puntos porcentuales entre modelos (56,2% vs 72,3%) reveló diferencias sustanciales en cómo interpretan las zonas de transición. El modelo CatBoost tiende a clasificar más píxeles como Ultisoles, un comportamiento atribuible a su estrategia

conservadora que favorece la clase mayoritaria cuando la señal es ambigua. En contraste, el modelo XGBoost redistribuye más área hacia Andisoles (20,5%) e Inceptisols (17,4%), sugiere mayor sensibilidad a gradientes altitudinales y geológicos.

Las mayores discrepancias entre modelos ocurrieron en órdenes con menor frecuencia en la cuenca, particularmente Histosoles. En ese sentido, XGBoost predijo un total de 88,08 km² (1,5% de la cuenca), RF predijo 37,40 km² (0,6%), mientras que CatBoost reportó apenas 2,17 km² (0,04%). Esta variabilidad 40 veces mayor entre extremos tiene implicaciones críticas para la gestión ambiental, ya que los Histosoles (suelos orgánicos) son indicadores de humedales y zonas de acumulación de carbono que requieren protección especial.

La ausencia completa de Histosoles en el conjunto de prueba (n=0) y su escasa representación en entrenamiento (n=3, 0.2%) podrían explicar estas discrepancias. Los modelos deben extrapolar debido a las pocas observaciones, resulta en predicciones altamente inciertas. XGBoost, con su mayor capacidad de ajuste, identifica más áreas potenciales basándose en combinaciones de baja pendiente, alta humedad y elevación media. CatBoost, con fuerte regularización, esencialmente ignora esta clase por su escasa evidencia. Este resultado subraya una limitación fundamental del enfoque: clases con <1% de representación en el dataset no pueden modelarse confiablemente con métodos supervisados estándar.

Los Andisoles demostraron una cobertura intermedia con notable variación: 14,4% (RF), 16,4% (CatBoost) y 20,5% (XGBoost) del área evaluada. Estos suelos volcánicos de media fertilidad están restringidos a elevaciones medias-altas (1500 - 3000 msnm) donde dominan cenizas volcánicas y temperatura baja (<18 °C). En ese sentido, XGBoost predijo la mayor extensión, consistente con su capacidad de capturar el gradiente altitudinal continuo y la transición gradual de Ultisoles a Inceptisoles y finalmente Andisoles.

La mayor área predicha por XGBoost (1229 km²) versus RF (865 km²) sugiere que identifica zonas de transición como Andisoles, mientras que RF las clasifica más conservadoramente como Inceptisoles.

Los Inceptisols, suelos jóvenes de desarrollo incipiente, respresentaron entre 7,0% (CatBoost) y 17,4% (XGBoost). Este orden de suelos representa zonas de transición en múltiples tipos de gradientes: altitudinal (entre Ultisoles de tierras bajas y Andisoles de altura), topográfico (laderas con erosión moderada) y geológico (sobre materiales recientemente depositados). La predicción más extensa de XGBoost (1043 km²) versus CatBoost (418 km²) refleja nuevamente

mayor sensibilidad a zonas ambiguas, interpretándolas como Inceptisols en lugar de colapsarlas en la clase dominante Ultisols.

La distribución de los órdenes de suelos en la cuenca del Río General de acuerdo con los tres modelos de clasificación se representa en las **Figuras 3, 4** y **5**. El motivo principal de este primer ejercicio de modelizado fue enfocarse en un área mayor, logra evitar generalizar la información, tener una capacidad mayor de características similares en sitios con influencias físicas similares o no tan similares. Para el caso de las **Figuras 3, 4** y **5**, se toma un área generalizada que involucra diferentes cuencas, con características diferentes de piedemonte, valles aluviales y otras estructuras geológicas que al ser involucradas ayudan a esta diferenciación de la información.

Finalmente, la distribución de los suelos de acuerdo con los tres modelos de clasificación en la cuenca del río Ceibo se representa en las **Figuras 6, 7** y **8**. Los tres modelos evaluados coinciden que el orden de los Ultisoles representa una gran mayoría del área de esta cuenca en específico, seguida por los Andisoles (**Figuras 6, 7 y 8**; **Tabla 10**).

Tabla 10. Cobertura espacial de órdenes de suelo por modelo evaluado en el mapeo digital de suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica.

Orden	RF (km²)	RF (%)	XGB (km²)	XGB (%)	CAT (km²)	CAT (%)
Ultisoles	181,67	60,62	188,69	62,96	227,72	75,99
Andisoles	51,20	17,1	53,36	17,81	48,98	16,34
Inceptisoles	7,002	2,34	34,99	11,67	15,80	5,27
Entisoles	43,50	14,51	13,44	4,49	2,39	0,8
Histosoles	1,35	0,45	0,007	0,001	0	0
Oxisoles	13,82	4,61	8,69	2,9	4,80	1,6
Alfisoles	1,14	0,38	0,50	0,17	0	0

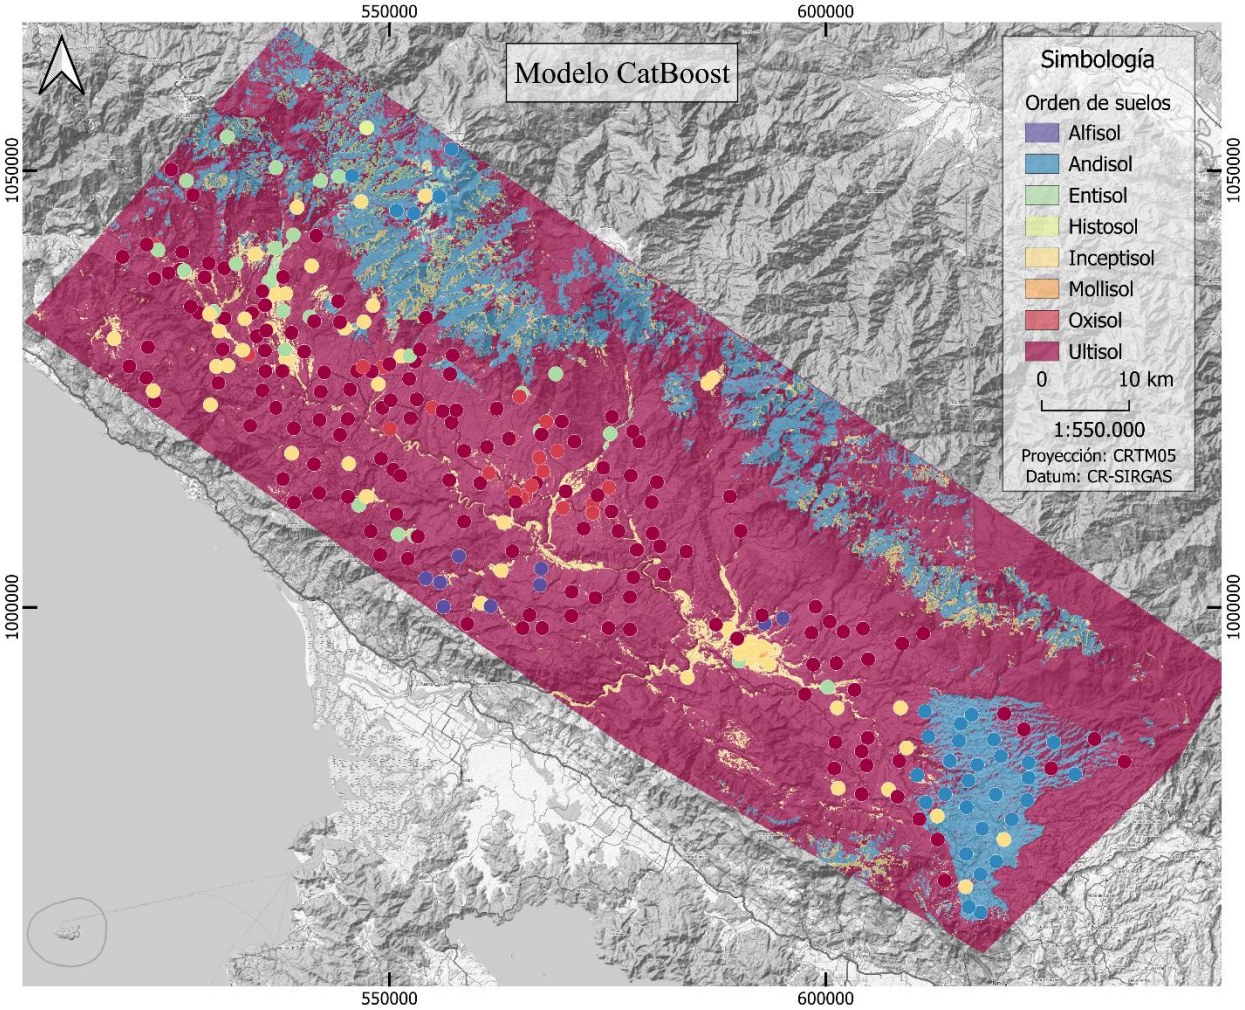

Figura 3. Mapeo digital de los suelos en la cuenca del Río General, Costa Rica realizado mediante el modelo CatBoost

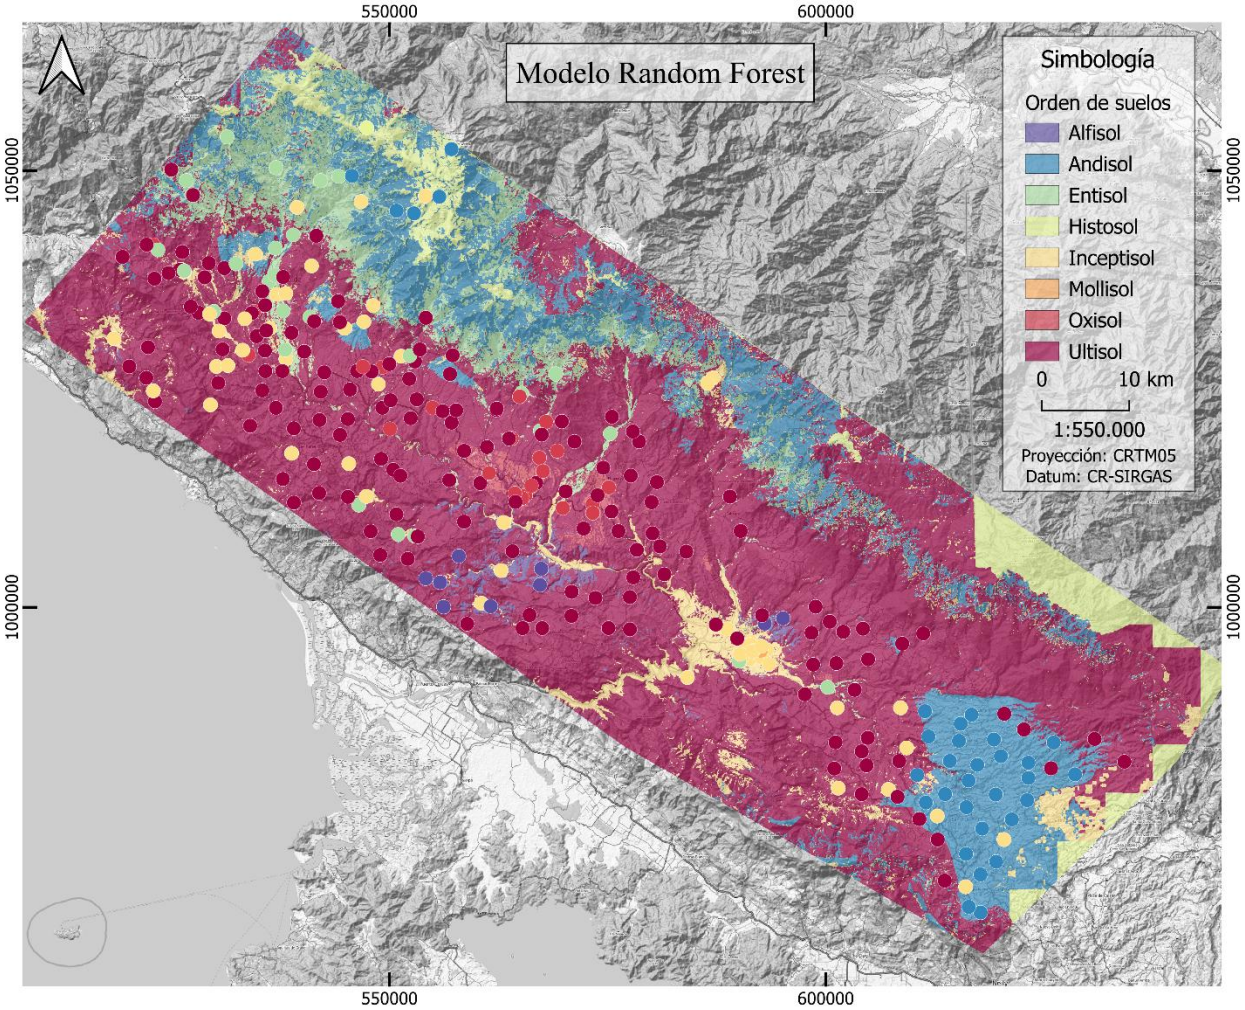

Figura 4. Mapeo digital de los suelos en la cuenca del Río General, Costa Rica realizado mediante el modelo Random Forest

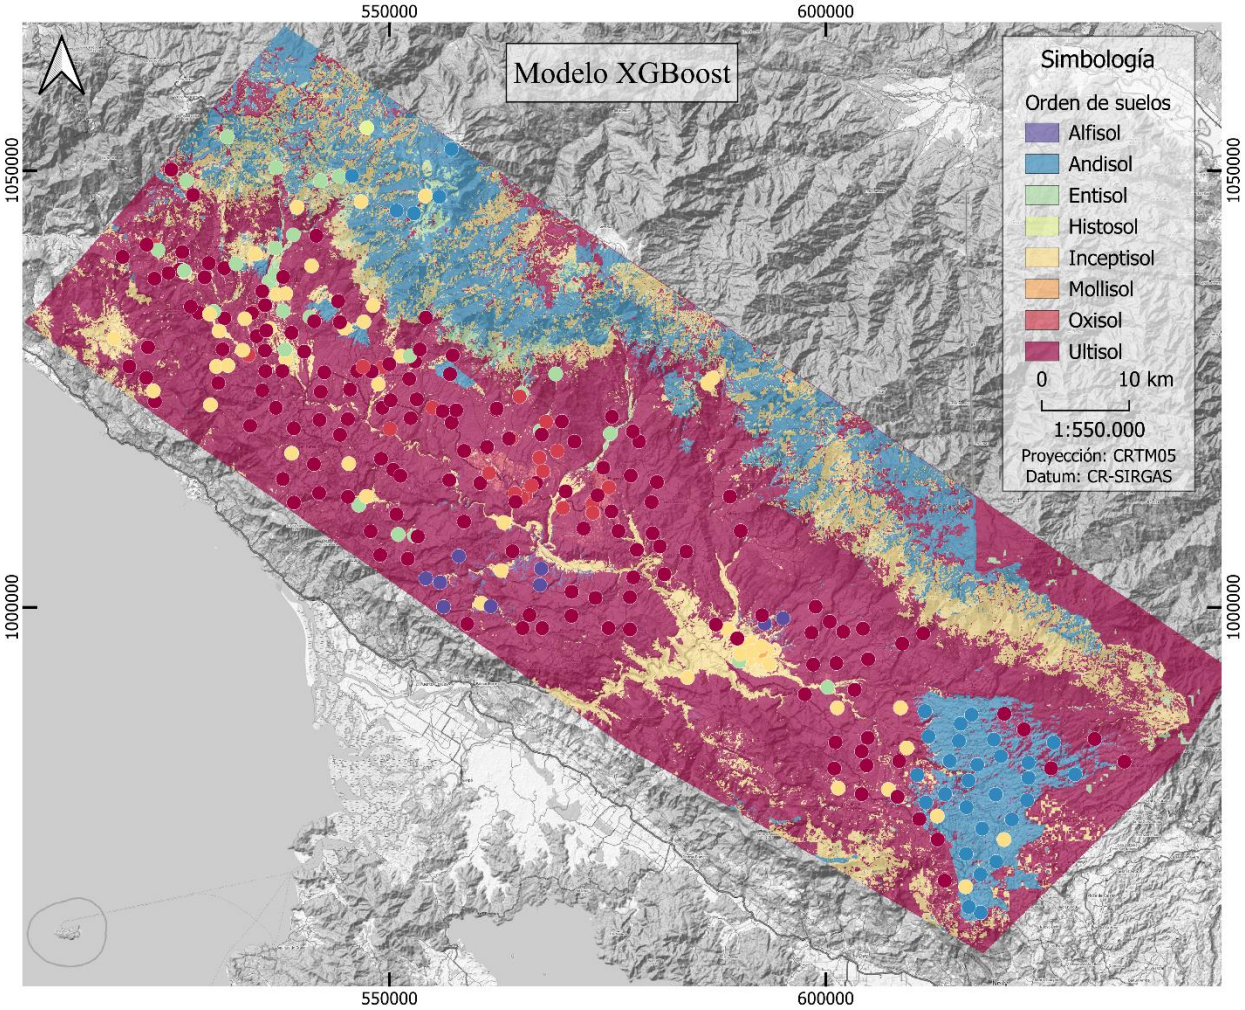

Figura 5. Mapeo digital de los suelos en la cuenca del Río General, Costa Rica realizado mediante el modelo XGBoost

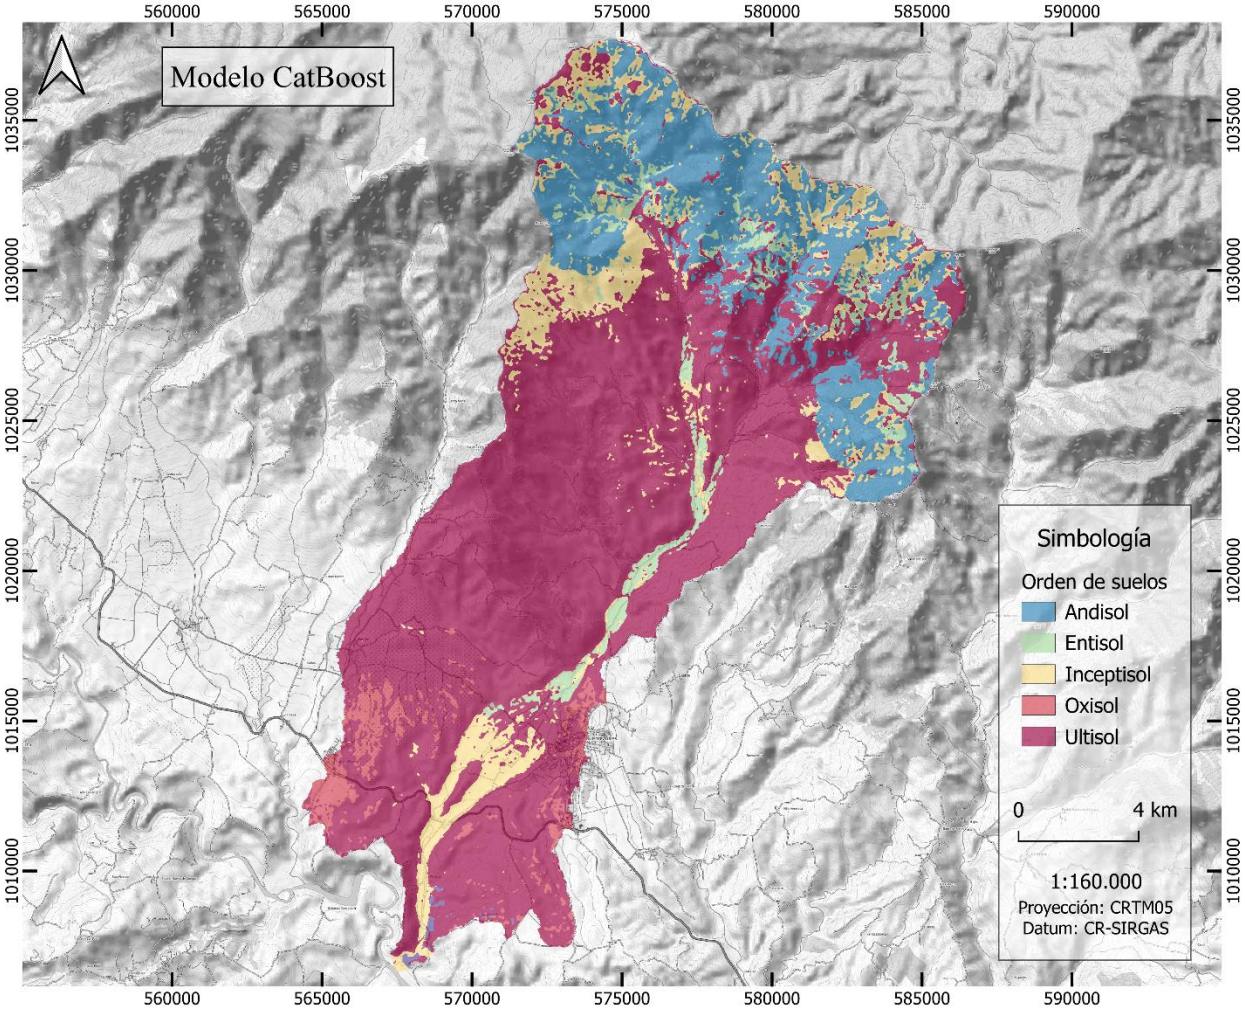

Figura 6. Mapeo digital de los suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica realizado mediante el modelo CatBoost

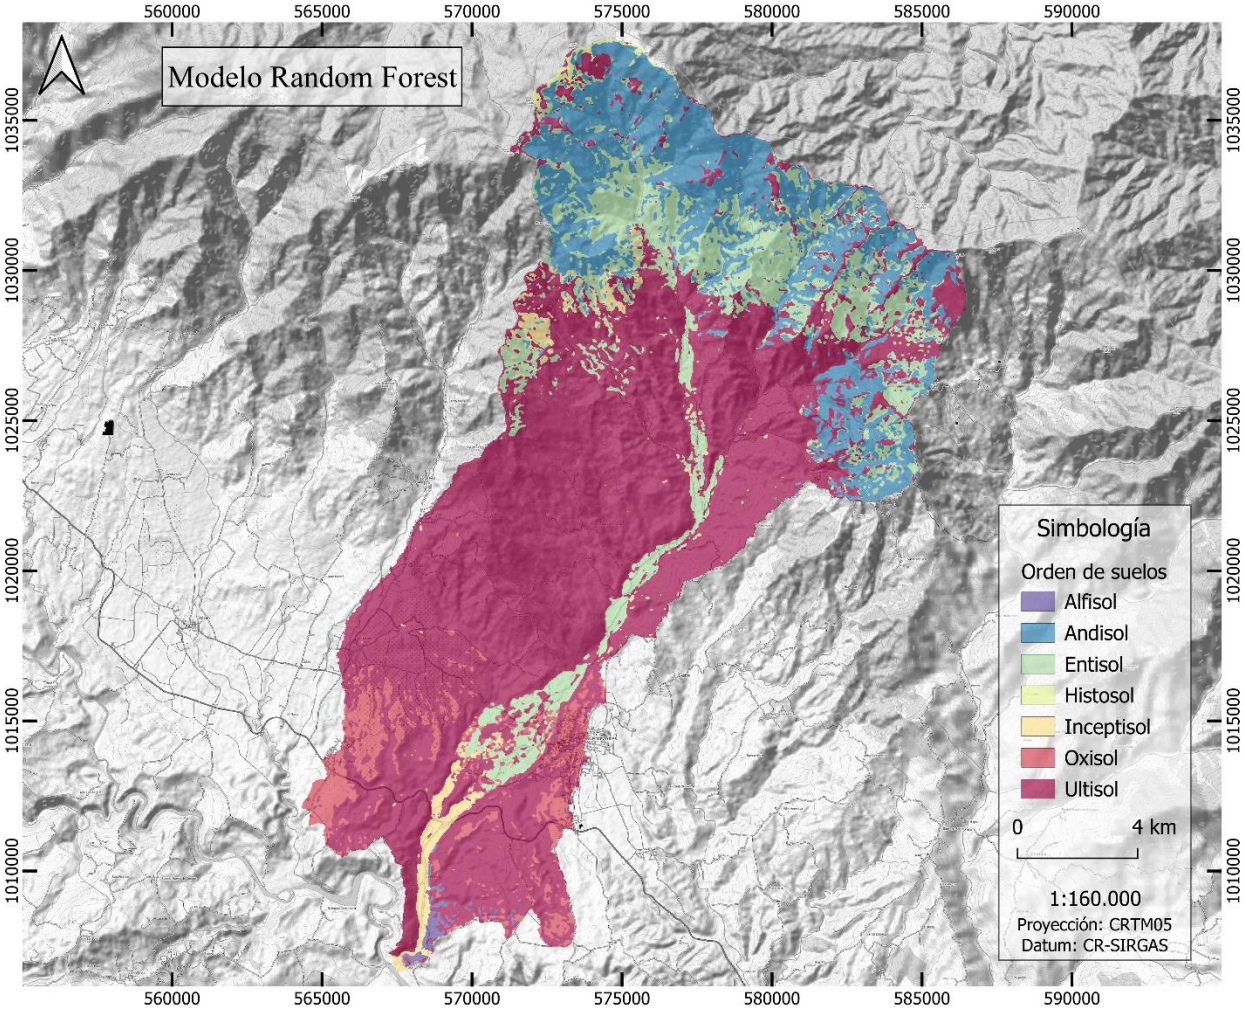

Figura 7. Mapeo digital de los suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica realizado mediante el modelo Random Forest

Al comparar los resultados de los modelos en ambas cuencas (**Tabla 9** y **Tabla 10**), se observó una clara concordancia en la jerarquía de los órdenes de suelo dominantes. En ambas cuencas, los Ultisoles se posicionaron consistentemente como la clase mayoritaria, representa entre el 56% y el 76% de la superficie total, seguidos de manera sistemática por los Andisoles, que mantienen una participación estable cercana al 14%-20%.

Al evaluar los parámetros de desempeño del modelo (**Tabla 4**) y los patrones de distribución de los distintos órdenes de suelo (como se observan en todas las **Figuras**), se consideró la predicción proveniente del modelo XGBoost como la más robusta, la cual representa en la **Figura 8**.

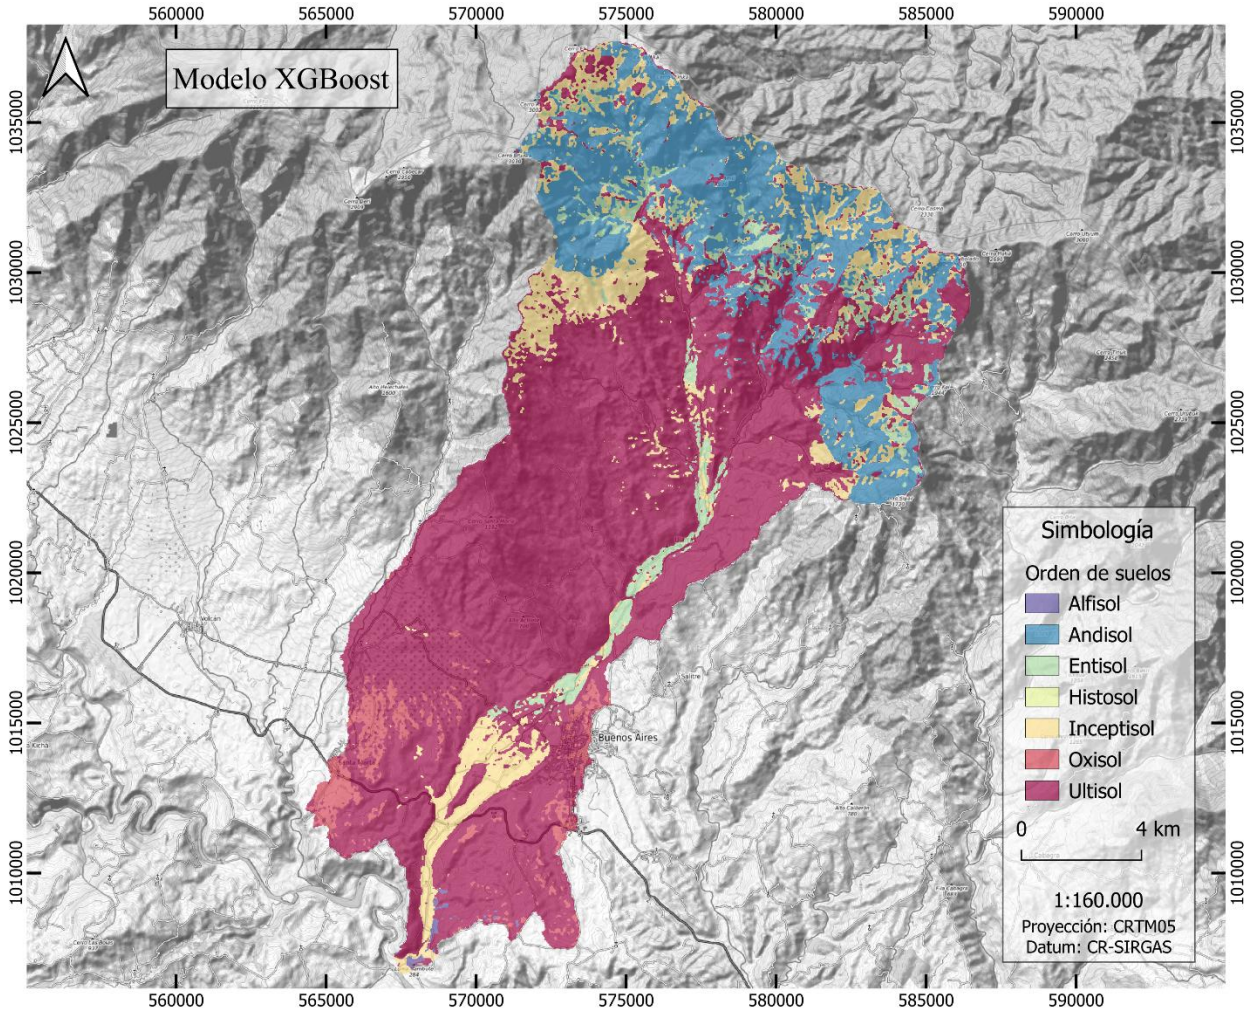

Figura 8. Mapeo digital de los suelos en la cuenca del Río Ceibo, Buenos Aires, Costa Rica realizado mediante el modelo XGBoost

DISCUSIÓN

Los resultados obtenidos confirman la alta capacidad de los modelos de aprendizaje automático para la predicción espacial de órdenes de suelos en contextos tropicales montañosos. XGBoost demostró un desempeño superior al capturar relaciones no lineales complejas entre las variables ambientales y las clases edáficas, lo cual coincide con estudios previos de cartografía digital de suelos en regiones heterogéneas (Hengl et al., 2017; Wadoux et al., 2020; Padarian et al., 2019; Ramcharan et al., 2018).

La dominancia de variables topográficas y climáticas, particularmente la elevación y la temperatura máxima, respalda el modelo conceptual de zonación altitudinal de suelos en ambientes tropicales (Jenny, 1941; Sarmiento, 1986; Buytaert et al., 2006). Asimismo, la identificación espacial coherente de Ultisoles, Andisoles e Inceptisoles valida la integración del enfoque geopedológico con técnicas de aprendizaje automático (Zinck et al., 2023; Hengl et al., 2017).

No obstante, el desbalance severo de clases limitó la capacidad predictiva para órdenes minoritarios como Mollisoles e Histosoles, evidencia una restricción inherente a los enfoques supervisados cuando la información de campo es escasa (Chawla et al., 2002; He et al., 2008). Este aspecto subraya la necesidad de fortalecer el muestreo dirigido y de explorar enfoques híbridos que integren conocimiento experto (Wadoux et al., 2019; Minasny et al., 2024).

La distribución espacial de los órdenes de suelos predichos refleja la interacción entre los factores formadores según el modelo CLORPT. Los Ultisoles dominantes en las tierras bajas y medias se asocian con condiciones geomorfológicas de valles aluviales y superficies de denudación antigua, donde la lixiviación intensa bajo clima tropical húmedo favorece la acumulación de arcillas iluviales (Jenny, 1941; Camacho et al., 2021). Las sabanas del Valle del río General, formación ecológica particular de la región sur de Costa Rica y se encuentran ubicadas en la cuenca del río Ceibo, corresponden espacialmente con sectores predichos como Ultisoles e Inceptisoles en suelos aluviales con drenaje moderado, condición consistente con lo documentado por Artavia & Ávalos (2020). Los Andisoles, restringidos a zonas de mayor altitud (>1 500 m s.n.m.), reflejan el control geomorfológico de los conos volcánicos y laderas de la Cordillera de Talamanca, donde el material parental ígneo y las bajas temperaturas ralentizan la meteorización, favoreciendo la acumulación de materiales amorfos tipo alofana (Camacho et al., 2020). La alta

precipitación en zonas elevadas (>3 000 mm/año) combinada con pendientes pronunciadas genera condiciones de lixiviación intensa y erosión activa, lo que explica la transición entre Andisoles, Inceptisoles y Entisoles observada a lo largo del gradiente altitudinal

Los resultados confirman que XGBoost representa una diferencia notable alcanza 96,2% de exactitud y supera consistentemente a RF y CatBoost en todas las métricas evaluadas. Este hallazgo es consistente con estudios recientes en pedometría digital que reportan la superioridad de gradient boosting sobre bagging en contextos de clasificación multiclase (Hengl et al., 2017; Wadoux et al., 2020; Chen & Guestrin, 2016; Taghizadeh-Mehrjardi et al., 2020). La clave del éxito de XGBoost radica en su capacidad de construcción secuencial de modelos, donde cada árbol nuevo corrige sistemáticamente los errores residuales del ensemble previo, permite capturar patrones progresivamente más sutiles (Chen & Guestrin, 2016; Ramcharan et al., 2018).

No obstante, la estrategia agresiva de XGBoost (300 árboles pequeños, learning rate bajo) requiere mayor tiempo computacional (14 segundos por predicción espacial) comparado con CatBoost (2 segundos). Este trade-off precisión-velocidad debe considerarse en aplicaciones operacionales que requieren actualización frecuente de mapas (Prokhorenkova et al., 2018). Para proyectos de investigación donde la precisión es prioritaria, XGBoost es claramente preferible; para sistemas de monitoreo en tiempo real, CatBoost podría ser más apropiado si se acepta una reducción de aproximadamente 10 puntos porcentuales en exactitud.

La regularización conservadora implementada en CatBoost (l2_leaf_reg=10) efectivamente previno sobreajuste (5,2%) pero penalizó excesivamente la complejidad del modelo, resulta un bajo desempeño en clases minoritarias. Este resultado sugiere que hiperparámetros óptimos para datasets balanceados no son apropiados para el fuerte desbalance presente en este estudio (53,9% Ultisoles, 0,2% Histosoles). Trabajos futuros deberían explorar técnicas de muestreo como SMOTE (Synthetic Minority Over-sampling Technique) o ponderación adaptativa de clases para mejorar el desempeño en órdenes raros sin sacrificar precisión global (Chawla et al., 2002; Batista et al., 2004; He et al., 2008; Douzas et al., 2018).

Según los resultados obtenidos por Heung et al. (2016) que se asemeja con el enfoque de la cartografía digital de suelos, utiliza algoritmos de aprendizaje automático tipo ensemble para modelar relaciones no lineales entre variables ambientales y clases edáficas. De manera consistente, la tesis adopta este mismo marco metodológico mediante la implementación de

Random Forest, XGBoost y CatBoost, que integra variables climáticas, topográficas, geomorfológicas y de cobertura vegetal bajo el modelo conceptual CLORPT.

A diferencia de que el desarrollo utilizado por Heung et al. es a una escala regional amplia, en este proceso se combina un entrenamiento regional (cuenca del río General) con una aplicación focalizada de cuenca (río Ceibo), estrategia que ha sido recomendada para mejorar la capacidad de generalización de los modelos en regiones con muestreo limitado (Hengl et al., 2017; Wadoux et al., 2021).

Los resultados del artículo ya mencionado evidencian la superioridad de los algoritmos de gradient boosting frente a métodos de bagging en contextos ambientalmente heterogéneos, debido a su capacidad de corregir errores residuales de forma secuencial (Chen & Guestrin, 2016; Ramcharan et al., 2018). Este patrón se replica claramente en la tesis, donde XGBoost alcanzó una exactitud global del 96,2% y un coeficiente Kappa de 0,941, supera consistentemente a Random Forest y CatBoost.

La concordancia entre ambos estudios refuerza la validez externa de los resultados obtenidos y confirma que el desempeño observado no es un caso aislado con la creación de mapas de suelos digitales (Hengl et al., 2017; Padarian et al., 2019).

Según se presenta en la información reportada por Heung et al. (2016) se identifica un control dominante de variables topográficas y climáticas sobre la distribución espacial de los suelos en ambientes montañosos tropicales, particularmente la elevación y la temperatura.De forma concordante, la tesis demuestra que la elevación, la temperatura máxima y las métricas geomorfométricas fueron los predictores más influyentes, respalda el modelo conceptual de zonación altitudinal de suelos (Jenny, 1941; Sarmiento, 1986; Buytaert et al., 2006).

La coincidencia en la jerarquía de variables refuerza la interpretación geopedológica del paisaje edáfico y confirma que los modelos de aprendizaje automático reflejan procesos pedogenéticos reales, más allá de una simple optimización estadística (Zinck et al., 2023; Hengl et al., 2017).

El fracaso de todos los modelos en predecir correctamente Mollisoles (F1=0.000 en los tres) y el desempeño deficiente en Histosols evidencia una limitación fundamental de enfoques supervisados en datasets pedológicos reales, que inherentemente presentan distribuciones altamente desbalanceadas refleja la dominancia natural de ciertos órdenes en cada región (Hengl et al., 2017; Elreedy & Atiya, 2023). Con solo 2-3 muestras de estas clases en los conjuntos de

entrenamiento y prueba, los algoritmos carecen de información suficiente para aprender sus patrones distintivos (Chawla et al., 2002; Blagus & Lusa, 2013).

Muestreo dirigido adicional: Realizar campañas de campo específicamente en áreas con alta probabilidad de contener órdenes poco usuales de observar en una unidad de paisaje (e.g., valles aluviales para Mollisoles, depresiones mal drenadas para Histosoles), aumenta su representación al menos a 1-2% del dataset total (Wadoux et al., 2019; Viscarra Rossel & Chen, 2011).

Modelado en dos etapas: Entrenar primero un modelo binario 'suelos frecuentes vs atípicos', luego modelos especializados para cada grupo, estrategia que ha mostrado éxito en taxonomías desbalanceadas (Brungard et al., 2015; Heung et al., 2016).

La dominancia de DEM y temperatura en el ranking de importancia valida el modelo conceptual de zonación altitudinal de suelos en montañas tropicales (Jenny, 1941; Sarmiento, 1986; McBratney et al., 2003). La elevación controla indirectamente múltiples procesos: temperatura (gradiente adiabático de aproximadamente 0,6 °C 100 m-1), régimen de humedad (nubes orográficas en elevaciones medias), mineralogía del material parental (actividad volcánica histórica concentrada en alturas), y uso de suelo (agricultura en tierras bajas, bosques en montañas) (Sarmiento, 1986; Buytaert et al., 2006; Jarvis & Stuart, 2001). Esta multicausalidad podría explicar el rol del DEM como el predictor más importante a pesar de no ser un factor formador directo (McBratney et al., 2003; Hengl et al., 2017).

La baja importancia de precipitación (No incluida en las principales 5 variables de entrada en todos los modelos evaluados) es contraintuitiva dado su rol conocido en lixiviación y meteorización (Jenny, 1941). Dos explicaciones son posibles:

Escala espacial inadecuada: El producto CHIRPS (resolución 5 km) no captura la variabilidad a escala de ladera que sí capturan variables topográficas de 30 m (Hengl et al., 2017; Mulder et al., 2011). La inadecuación de escalas espaciales entre variables predictoras ha sido documentada por Hengl et al. (2017), quienes demostraron que el desajuste de resoluciones puede introducir errores sistemáticos en modelos de aprendizaje automático.

Redundancia con elevación: En regiones montañosas tropicales, la precipitación está fuertemente correlacionada con altitud (efecto orográfico), resulta en colinealidad que reduce su importancia aparente en modelos de árboles que priorizan el primer predictor en divisiones (Jarvis & Stuart, 2001; Buytaert et al., 2006; McBratney et al., 2003). Este efecto orográfico de

precipitación-elevación en zonas montañosas tropicales ha sido ampliamente documentado por Jarvis & Stuart (2001) y Buytaert et al. (2006), quienes encontraron correlaciones r > 0.7 entre precipitación y elevación.

El rol significativo de geología en XGBoost (tercera posición) confirma que el material parental que son determinante para clasificación al nivel de orden, particularmente para distinguir Andisoles (cenizas volcánicas) de otros órdenes (Soil Survey Staff, 2014; Jenny, 1941). Sin embargo, su posición relativamente baja sugiere que, en escalas regionales, los factores topo-climáticos (que varían continuamente en el espacio) tienen mayor poder predictivo que litología (que varía categóricamente), hallazgo consistente con McBratney et al. (2003) quien argumenta que, en paisajes heterogéneos, el relieve supera a la geología como factor formador dominante porque integra efectos de erosión, deposición y redistribución de agua (Amundson & Jenny, 1997).

Las discrepancias sustanciales entre modelos en la distribución espacial de clases minoritarias (e.g., Histosoles: 2-88 km²) revelan alta incertidumbre en zonas de transición donde la señal ambiental es ambigua (Kempen et al., 2012; Lagacherie et al., 2019). En lugar de seleccionar un único 'mejor' modelo, se recomienda un enfoque de ensamblado que combine las tres predicciones mediante votación ponderada por desempeño: asignar 50% de peso a XGBoost, 30% a RF y 20% a CatBoost (Zhou, 2012; Heung et al., 2016). Este mapa consensuado captura la incertidumbre inherente al proceso: píxeles donde los tres modelos concuerdan tienen alta confianza, mientras que desacuerdos indican zonas que requieren verificación de campo (Wolpert, 1992; Caubet et al., 2019).

Adicionalmente, se recomienda generar mapas de probabilidad de clase que, para cada píxel, muestren la distribución de probabilidades sobre los 8 órdenes en lugar de una clasificación (Kempen et al., 2012; Lagacherie et al., 2019). Esta información probabilística es más útil para toma de decisiones: permite identificar zonas con clasificaciones ambiguas (probabilidades repartidas entre varias clases) que son candidatas prioritarias para muestreo adicional, versus zonas con alta certeza (>90% probabilidad en una clase) donde el mapa es confiable (Kempen et al., 2012). Métodos bayesianos como Gaussian Process Classification podrían explorar esta dirección (Rasmussen & Williams, 2006).

Rasmussen & Williams (2006) proporcionan el marco teórico completo para Gaussian Processes en clasificación; su aplicación en pedometría digital ha sido exitosamente demostrada por Kempen et al. (2012) para cuantificar incertidumbre espacial en mapas de suelos.

Limitaciones del Estudio y Direcciones Futuras

El estudio se desarrolló a escala regional, la clasificación de los suelos al nivel de orden según Soil Taxonomy, lo cual resulta adecuado para planificación territorial, pero insuficiente para aplicaciones de manejo a escala local (Soil Survey Staff, 2014; Hengl et al., 2017). La dependencia de calicatas existentes, la resolución espacial de 30 m y la ausencia de validación espacial independiente constituyen limitaciones metodológicas (Meyer & Pebesma, 2021; Roberts et al., 2017). Este estudio presenta varias limitaciones que deben considerarse al interpretar resultados:

Validación espacial limitada: La partición aleatoria 70/30 no considera autocorrelación espacial; puntos cercanos en train y test pueden compartir información, que aumenta las métricas de desempeño (Meyer & Pebesma, 2021; Roberts et al., 2017). Validación cruzada espacial con bloques geográficos separados proporcionaría estimaciones más conservadoras de error de generalización (Wadoux et al., 2021).

Resolución taxonómica fija: Clasificar al nivel de orden (1° nivel de Soil Taxonomy) es apropiado para planificación regional, pero insuficiente para diseño de manejo a escala de finca (Soil Survey Staff, 2014). Estudios futuros deberían explorar clasificación jerárquica Orden, Suborden y Gran Grupo (Hengl et al., 2017).

Covariables estáticas: NDVI y uso de suelo son dinámicos, pero se usaron promedios anuales; incorporar series temporales permitiría capturar variabilidad estacional en vegetación que puede asociarse con propiedades de suelos (Gómez et al., 2016; Demattê et al., 2020).

Deep learning convolucional: Redes neuronales tipo U-Net que aprenden automáticamente representaciones jerárquicas de patrones espaciales en imágenes de covariables, potencialmente supera a los árboles de decisión (Padarian et al., 2019; Zhang et al., 2019).

Transferencia de aprendizaje: Pre-entrenar modelos en regiones con datos abundantes, luego adaptar a cuencas con muestreo escaso mediante fine-tuning (Tajik et al., 2020).

Fusión de sensores remotos multiespectrales: Integrar reflectancia visible-infrarroja de Sentinel-2 con radar de Sentinel-1 para capturar humedad del suelo y textura superficial, atributos diagnósticos para clasificación taxonómica (Mulder et al., 2011; Demattê et al., 2020; Viscarra Rossel & Chen, 2011).

CONCLUSIONES

La integración de enfoques geopedológicos, análisis geomorfológico y modelos de aprendizaje automático permitió una caracterización robusta y detallada de los suelos presentes en la cuenca del río Ceibo. Los resultados obtenidos confirman que la combinación de variables topográficas, climáticas y temáticas representa adecuadamente los factores formadores del suelo, permite capturar patrones espaciales coherentes con la dinámica ambiental de una región tropical montañosa.

Los tres modelos implementados (Random Forest, XGBoost y CatBoost) mostraron un desempeño satisfactorio en la clasificación de órdenes de suelos, aunque con diferencias significativas en precisión, capacidad de generalización y tratamiento de clases minoritarias. XGBoost se consolidó como el modelo con mejor desempeño global, alcanza la mayor exactitud y coeficiente Kappa, así como el menor grado de sobreajuste, lo que evidencia su alta capacidad para modelar relaciones complejas suelo–paisaje. Random Forest destacó por su estabilidad y balance entre precisión y robustez, mientras que CatBoost mostró un comportamiento más conservador, limita la detección de clases poco representadas.

La distribución espacial de los órdenes de suelos predicha por los modelos es consistente con el conocimiento edafológico previo de la región, destacándose el claro predominio de Ultisoles en las tierras bajas y medias de la cuenca, asociados a condiciones de alta meteorización y lixiviación. Asimismo, la identificación de Andisoles en zonas de mayor altitud y de Inceptisols en áreas de transición altitudinal y geomorfológica refuerza la importancia del relieve y la temperatura como variables clave en la formación y diferenciación de los suelos. No obstante, la alta incertidumbre asociada a órdenes minoritarios como Histosoles y Mollisoles pone de manifiesto una limitación inherente a los enfoques supervisados cuando la representación muestral es escasa.

El análisis de importancia de variables evidenció el papel dominante de la elevación, la temperatura máxima y las variables geomorfométricas, confirma el fuerte control topoclimático sobre los procesos pedogenéticos en la cuenca. La menor relevancia de variables como la precipitación y el uso del suelo sugiere que su influencia está parcialmente capturada por variables correlacionadas, o bien que su impacto es secundario frente a gradientes altitudinales pronunciados.

Desde una perspectiva aplicada, los mapas predictivos generados y la propuesta de unidades geopedológicas constituyen un insumo valioso para el ordenamiento territorial, la

planificación agrícola y la gestión ambiental en el cantón de Buenos Aires de Puntarenas. Este estudio demuestra que el uso de técnicas de aprendizaje automático, combinadas con fundamentos teóricos sólidos de la geopedología, representa una alternativa eficiente y replicable para la cartografía de suelos en regiones con información limitada.

La integración de análisis geomorfológico, variables ambientales y modelos de aprendizaje automático permitió caracterizar de manera robusta la distribución espacial de los suelos en la cuenca del río Ceibo. Los resultados evidencian un fuerte control topoclimático en los procesos pedogenéticos y confirman la utilidad del enfoque geopedológico para interpretar el paisaje edáfico.

XGBoost se consolidó como el modelo con mejor desempeño predictivo, mientras que Random Forest y CatBoost ofrecieron perspectivas complementarias. La propuesta de unidades geopedológicas derivada de estos resultados constituye un insumo técnico relevante para el ordenamiento territorial y la gestión ambiental en el cantón de Buenos Aires de Puntarenas.

Finalmente, este estudio sienta un precedente metodológico para futuras investigaciones geopedológicas en Costa Rica, demuestra que el uso combinado de fundamentos teóricos sólidos y técnicas avanzadas de análisis espacial puede suplir parcialmente la carencia de información edafológica detallada

REFERENCIAS BIBLIOGRÁFICAS

Amundson, R., & Jenny, H. (1997). On a state factor model of ecosystems. BioScience, 47(8), 536-543.

Artavia G. & Ávalos G. (2020). Historia natural del ecosistema de sabana del Valle del Río General, Costa Rica. Revista Geográfica 161. ISSN: 2663-399X

Aydın, Y., Işıkdağ, Ü., Bekdaş, G., Nigdeli, S. M., & Geem, Z. W. (2023). Use of machine learning techniques in soil classification. Sustainability, 15(3), 2374. https://doi.org/10.3390/su15032374

Batista, G. E., Prati, R. C., & Monard, M. C. (2004). A study of the behavior of several methods for balancing machine learning training data. ACM SIGKDD Explorations Newsletter, 6(1), 20-29.

Bentéjac, C., Csörgő, A., & Martínez-Muñoz, G. (2021). A comparative analysis of gradient boosting algorithms. Artificial Intelligence Review, 54(3), 1937-1967. https://doi.org/10.1007/s10462-020-09896-5

Bergoeing, J. P. (2012). Geomorfología de Costa Rica. In P. Denyer & S. Kussmaul (Eds.), Geología de Costa Rica (pp. 329-358). Editorial Tecnológica de Costa Rica.

Blagus, R., & Lusa, L. (2013). SMOTE for high-dimensional class-imbalanced data. BMC Bioinformatics, 14(106), 1-16. https://doi.org/10.1186/1471-2105-14-106

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5-32. https://doi.org/10.1023/A:1010933404324

Brungard, C. W., Boettinger, J. L., Duniway, M. C., Wills, S. A., & Edwards Jr, T. C. (2015). Machine learning for predicting soil classes in three semi-arid landscapes. Geoderma, 239, 68-83.

Buytaert, W., Celleri, R., De Bièvre, B., Cisneros, F., Wyseure, G., Deckers, J., & Hofstede, R. (2006). Human impact on the hydrology of the Andean páramos. *Earth-Science Reviews*, *79*(1-2), 53-72. https://doi.org/10.1016/j.earscirev.2006.06.002

Camacho, M. E., Mata, R., Barrantes-Víquez, M., & Alvarado, A. (2021). Morphology and characteristics of eight Oxisols in contrasting landscapes of Costa Rica. Catena, 197, 104992.

Camacho, M. E., Quesada-Román, A., Mata, R., & Alvarado, A. (2020). Soil-geomorphology relationships of alluvial fans in Costa Rica. Geoderma Regional, 21, e00258. https://doi.org/10.1016/j.geodrs.2020.e00258

Camacho-Umaña, M.E., Quesada-Román, A., Villatoro-Sánchez, M., Alemán-Montes, B., Mata, R., Henríquez-Henríquez, C., Céspedes-Rivera, J., Céspedes-Rivera, M., Alvarado, A. (2024). Agricultural Landscapes of Costa Rica. In: Quesada-Román, A. (eds) Landscapes and Landforms of Costa Rica. World Geomorphological Landscapes. Springer, Cham. https://doi.org/10.1007/978-3-031-64940-0_11

Caubet, M., Román Dobarco, M., Arrouays, D., Minasny, B., & Saby, N. P. A. (2019). Merging country, continental and global predictions of soil texture: Lessons from ensemble modelling in France. Geoderma, 337, 99-110. https://doi.org/10.1016/j.geoderma.2018.09.017

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16, 321-357. https://doi.org/10.1613/jair.953

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785-794). https://doi.org/10.1145/2939672.2939785

Cohen, J. (1960). A coefficient of agreement for nominal scales. Educational and Psychological Measurement, 20(1), 37–46. https://doi.org/10.1177/001316446002000104

Congalton, R. G. (1991). A review of assessing the accuracy of classifications of remotely sensed data. Remote Sensing of Environment, 37(1), 35–46. https://doi.org/10.1016/0034-4257(91)90048-B

Cutler, A., Cutler, D.R., Stevens, J.R. (2012). Random Forests. In: Zhang, C., Ma, Y. (eds) Ensemble Machine Learning. Springer, New York, NY. https://doi.org/10.1007/978-1-4419-9326-7_5

Demattê, J. A. M., Dotto, A. C., Paiva, A. F. S., Sato, M. V., Dalmolin, R. S. D., Araújo, M. D. S. B., ... & Ruiz, L. F. C. (2020). The Brazilian Soil Spectral Library (BSSL): A general view, application and challenges. Geoderma, 354, 113793. https://doi.org/10.1016/j.geoderma.2019.05.043

Denyer, P. & Kussmaul, S. (2012). Geología de Costa Rica. Colombia: Instituto Tecnológico de Costa Rica.

Denyer, P., Alvarado, G. E., & Aguilar, T. (2014). Cartografía geológica de Costa Rica. Revista Geológica de América Central, Volumen Especial, 1-165.

Dietterich, T. G. (2000). Ensemble methods in machine learning. In J. Kittler & F. Roli (Eds.), *Multiple Classifier Systems* (pp. 1-15). Springer. https://doi.org/10.1007/3-540-45014-9_1

Douzas, G., Bacao, F., & Last, F. (2018). Improving imbalanced learning through a heuristic oversampling method based on k-means and SMOTE. Information Sciences, 465, 1-20. https://doi.org/10.1016/j.ins.2018.06.056

Elreedy, D., & Atiya, A. F. (2023). A theoretical distribution analysis of synthetic minority oversampling technique (SMOTE) for imbalanced learning. Machine Learning, 113, 4903-4923. https://doi.org/10.1007/s10994-022-06296-4

FAO (2022). Land Cover Classification System and land use datasets derived from Sentinel-2.

Foody, G. M. (2002). Status of land cover classification accuracy assessment. Remote Sensing of Environment, 80(1), 185–201. https://doi.org/10.1016/S0034-4257(01)00295-4

Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The Climate Hazards Infrared Precipitation with Stations (CHIRPS): A new environmental record for monitoring extremes. Scientific Data, 2, 150066. https://doi.org/10.1038/sdata.2015.66

Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Rowland, J., Husak, G., Harrison, L., Hoell, A., & Michaelsen, J. (2019). A high-resolution 1983–2016 temperature

climatology for the globe based on infrared satellite observations. Scientific Data, 6, 35. https://doi.org/10.1038/s41597-019-0041-7

Gillies, S., & others. (2013). Rasterio: Geospatial raster I/O for Python programmers [Software]. Mapbox. https://github.com/rasterio/rasterio

Gómez, C., Viscarra Rossel, R. A., & McBratney, A. B. (2016). Soil organic carbon prediction by hyperspectral remote sensing and field vis-NIR spectroscopy: An Australian case study. Geoderma, 146, 403-411.

Gómez-Guzmán, A. (2005). Geomorfología. In A. Gómez-Guzmán (Ed.), Principios básicos de geomorfología (pp. 15-48). Universidad Nacional Autónoma de México.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. Nature, 585(7825), 357-362. https://doi.org/10.1038/s41586-020-2649-2

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

He, H., Bai, Y., Garcia, E. A., & Li, S. (2008). ADASYN: Adaptive synthetic sampling approach for imbalanced learning. In Proceedings of the International Joint Conference on Neural Networks (pp. 1322-1328). https://doi.org/10.1109/IJCNN.2008.4633969

Hengl, T., Mendes de Jesus, J., Heuvelink, G. B., Ruiperez Gonzalez, M., Kilibarda, M., Blagotić, A., Shangguan, W., Wright, M. N., Geng, X., Bauer-Marschallinger, B., Guevara, M. A., Vargas, R., MacMillan, R. A., Batjes, N. H., Leenaars, J. G., Ribeiro, E., Wheeler, I., Mantel, S., & Kempen, B. (2017). SoilGrids250m: Global gridded soil information based on machine learning. *PLOS ONE*, *12*(2), e0169748. https://doi.org/10.1371/journal.pone.0169748

Hengl, T., Nussbaum, M., Wright, M. N., Heuvelink, G. B., & Gräler, B. (2018). Random forest as a generic framework for predictive modeling of spatial and spatio-temporal variables. PeerJ, 6, e5518.

Heung, B., Bulmer, C. E., & Schmidt, M. G. (2014). Predictive soil parent material mapping at a regional-scale: A Random Forest approach. *Geoderma*, *214-215*, 141-154. https://doi.org/10.1016/j.geoderma.2013.09.016

Heung, B., Ho, H. C., Zhang, J., Knudby, A., Bulmer, C. E., & Schmidt, M. G. (2016). An overview and comparison of machine-learning techniques for classification purposes in digital soil mapping. *Geoderma*, *265*, 62-77. https://doi.org/10.1016/j.geoderma.2015.11.014

Hughes, J. D., Alvarado, E., & Rojas, C. (2017). Geografía y uso del suelo en Costa Rica. Editorial Costa Rica.

IMN. Instituto Meteorológico Nacional. (2023). Climatología de la región. https://www.imn.ac.cr/climatologia

Japan Aerospace Exploration Agency (JAXA). (2006). ALOS PALSAR Level 1.1/1.5 product format description. Earth Observation Research Center.

Jarvis, A., & Stuart, N. (2001). A comparison among strategies for interpolating maximum and minimum daily air temperatures. Part II: The interaction between number of guiding variables and the type of interpolation method. *Journal of Applied Meteorology*, *40*(6), 1075-1084. https://doi.org/10.1175/1520-0450(2001)040<1075:ACASFI>2.0.CO;2

Jasiewicz, J., & Stepinski, T. F. (2013). Geomorphons: A pattern recognition approach to classification and mapping of landforms. Geomorphology, 182, 147–156.

Jenny, H. (1941). Factors of Soil Formation: A System of Quantitative Pedology. McGraw-Hill, New York.

Jordahl, K., Van den Bossche, J., Fleischmann, M., Wasserman, J., McBride, J., Gerard, J., Tratner, J., Perry, M., Badaracco, A. G., Farmer, C., Hjelle, G. A., Snow, A. D., Cochran, M., Gillies, S., Culbertson, L., Bartos, M., Eubank, N., maxalbert, Bilogur, A., ... Leblanc, F. (2020). geopandas/geopandas: v0.8.1 (Version v0.8.1). Zenodo. https://doi.org/10.5281/zenodo.3946761

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. ACM Transactions on Knowledge Discovery from Data, 6(4), 15.

Kempen, B., Brus, D. J., & Stoorvogel, J. J. (2011). Three-dimensional mapping of soil organic matter content using soil type-specific depth functions. *Geoderma*, *162*(1-2), 107-123. https://doi.org/10.1016/j.geoderma.2011.01.010

Kempen, B., Brus, D. J., Heuvelink, G. B., & Stoorvogel, J. J. (2009). Updating the 1:50,000 Dutch soil map using legacy soil data: A multinomial logistic regression approach. *Geoderma*, *151*(3-4), 311-326. https://doi.org/10.1016/j.geoderma.2009.04.023

Kempen, B., Brus, D. J., Heuvelink, G. B., & Stoorvogel, J. J. (2012). Pedometric mapping of soil organic matter using a soil map with quantified uncertainty. *European Journal of Soil Science*, *63*(3), 333-347. https://doi.org/10.1111/j.1365-2389.2012.01439.x

Kuncheva, L. I., & Whitaker, C. J. (2003). Measures of diversity in classifier ensembles and their relationship with the ensemble accuracy. *Machine Learning*, *51*(2), 181-207. https://doi.org/10.1023/A:1022859003006

Lagacherie, P., Arrouays, D., Bourennane, H., Gomez, C., Martin, M., & Saby, N. P. A. (2019). How far can the uncertainty on a digital soil map be known? A numerical experiment using pseudo values of clay content obtained from Vis-SWIR hyperspectral imagery. Geoderma, 337, 1320-1328. https://doi.org/10.1016/j.geoderma.2018.08.024

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, *33*(1), 159-174. https://doi.org/10.2307/2529310

Madrigal, J., González, R., & Villalobos, A. (2022). Sistemas de suelos en la cuenca del río Ceibo y su capacidad productiva. Revista de Ecología y Agricultura, 15(2), 115-130.

Mallavan, B. P., Minasny, B., & McBratney, A. B. (2010). Homosoil, a methodology for quantitative extrapolation of soil information across the globe. In J. L. Boettinger, D. W. Howell, A. C. Moore, A. E. Hartemink, & S. Kienast-Brown (Eds.), *Digital Soil Mapping* (pp. 137-150). Springer. https://doi.org/10.1007/978-90-481-8863-5_12

Mata, R., Rosales, A., Vásquez, A., Sandoval, D. (2013). Mapa de Órdenes de Suelos de Costa Rica. 2a Ed. San José, Costa Rica. Asociación Costarricense de la Ciencia del Suelo. Esc 1: 200.000. Color.

McBratney, A. B., Mendonça Santos, M. L., & Minasny, B. (2003). On digital soil mapping. Geoderma, 117(1-2), 3-52.

McKinney, W. (2010). Data structures for statistical computing in Python. En Proceedings of the 9th Python in Science Conference (pp. 51–56). SciPy. https://doi.org/10.25080/Majora-92bf1922-00a

Meyer, H., & Pebesma, E. (2021). Predicting into unknown space? Estimating the area of applicability of spatial prediction models. Methods in Ecology and Evolution, 12(9), 1620-1633. https://doi.org/10.1111/2041-210X.13650

Minasny, B., McBratney, A. B., Wadoux, A. M. J. C., Adetsu, D., & Behrens, T. (2024). Soil science-informed machine learning. Geoderma, 452, 117094. https://doi.org/10.1016/j.geoderma.2024.117094

Mitchell, T. M. (1997). Machine Learning. McGraw-Hill.

Mulder, V. L., de Bruin, S., Schaepman, M. E., & Mayr, T. R. (2011). The use of remote sensing in soil and terrain mapping—A review. Geoderma, 162(1-2), 1-19. https://doi.org/10.1016/j.geoderma.2010.12.018

Obando L. G. & Kussmaul S. (2009). Geología de la hoja Buenos Aires, Costa Rica. Revista Geológica de América Central, 41: 123-136, 2009. ISSN: 0256-7024

Padarian, J., Minasny, B., & McBratney, A. B. (2019). Using deep learning for digital soil mapping. *SOIL*, *5*(1), 79-89. https://doi.org/10.5194/soil-5-79-2019

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.

Posada Arrubla, Adriana, & Ramírez Poveda, Hanner Yesid. (2015). Aproximación a la gestión territorial rural desde un modelo de ordenamiento agroambiental. Revista U.D.C.A Actualidad & Divulgación Científica, 18(2), 513-523.

Powers, D. M. W. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. Journal of Machine Learning Technologies, 2(1), 37–63.

Programa Estado de la Nación. (2020). Informe sobre recursos hídricos y cambio climático en Costa Rica. https://www.estadonacion.or.cr

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems 31* (pp. 6638-6648). Curran Associates.

Python Software Foundation. (2023). Python language reference (Version 3.11) [Software]. https://www.python.org/

Quesada-Román, A., & Peralta-Reyes, M. (2023). Geomorphological mapping global trends and applications. Geographies, 3(3), 610-621; https://doi.org/10.3390/geographies3030032

Quesada-Román, A., Hidalgo, H. G., & Alfaro, E. J. (2024). Assessing the impact of tropical cyclones on economic sectors in Costa Rica, Central America. Tropical Cyclone Research and Review, 13(3), 196-207.

Quesada-Román, A., Umaña-Ortíz, J., Zumbado-Solano, M., Islam, A., Abioui, M., Tefogoum, G. Z., ... & Pupim, F. (2023). Geomorphological regional mapping for environmental planning in developing countries. Environmental Development, 48, 100935.

Ramcharan, A., Hengl, T., Nagle, T., Verzani, R., Hassall, J., Reyes, T., & Vargas, R. (2018). Soil property and class maps of the conterminous United States at 100-meter spatial resolution. *Soil Science Society of America Journal*, *82*(1), 186-201. https://doi.org/10.2136/sssaj2017.04.0122

Rasmussen, C. E., & Williams, C. K. I. (2006). *Gaussian processes for machine learning*. MIT Press. https://doi.org/10.7551/mitpress/3206.001.0001

Riley, S. J., DeGloria, S. D., & Elliot, R. (1999). A terrain ruggedness index that quantifies topographic heterogeneity. Intermountain Journal of Sciences, 5(1-4), 23-27.

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., ... & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. Ecography, 40(8), 913-929. https://doi.org/10.1111/ecog.02881

Rojas, A., Mendoza, D., & Vargas, P. (2021). Biodiversidad y conservación en áreas tropicales húmedas: un caso de estudio en la cuenca del río Ceibo. Revista Costarricense de Ciencias Ambientales, 34, 202-220.

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLOS ONE, 10(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Sarmiento, G. (1986). Ecological Features of Climate in High Tropical Mountains. Oxford University Press.

Soil Survey Staff, USDA (1999) Soil Taxonomy: A Basic System of Soil Classification for Making and Interpreting Soil Surveys. Agriculture Handbook, Second Edition, No. 436.

Soil Survey Staff. (2014). Keys to Soil Taxonomy. 12th ed. USDA-Natural Resources Conservation Service, Washington, DC.

Soil Survey Staff. (2022). Keys to soil Taxonomy (13th ed.). USDA Natural Resources Conservation Service.

Taghizadeh-Mehrjardi, R., Nabiollahi, K., Rasoli, L., Kerry, R., & Scholten, T. (2020). Land suitability assessment and agricultural production sustainability using machine learning models. *Agronomy*, *10*(4), 573. https://doi.org/10.3390/agronomy10040573

Tajik, S., Ayoubi, S., & Zeraatpisheh, M. (2020). Digital mapping of soil organic carbon using ensemble learning model in Mollisols of Hyrcanian forests, Northern Iran. Geoderma Regional, 20, e00256. https://doi.org/10.1016/j.geodrs.2020.e00256

Tencio, A (2025). Modelado de unidades Geopedológico mediante Random Forest, XGBoost y CatBoost. Tesis: Clasificación supervisada de unidades geopedológicas para cuenca del río Ceibo, Buenos Aires, Puntarenas. https://github.com/AlexTencio/Prediccion_geopedolog-a_Ceibo.git

The pandas development team. (2020). pandas-dev/pandas: Pandas (Version 1.0.3). Zenodo. https://doi.org/10.5281/zenodo.3509134

Viscarra Rossel, R. A., & Chen, C. (2011). Digitally mapping the information content of visible–near infrared spectra of surficial Australian soils. *Remote Sensing of Environment*, *115*(6), 1443-1455. https://doi.org/10.1016/j.rse.2011.02.004

Wadoux, A. M. J. C., Heuvelink, G. B. M., de Bruin, S., & Brus, D. J. (2021). Spatial cross-validation is not the right way to evaluate map accuracy. Ecological Modelling, 457, 109692. https://doi.org/10.1016/j.ecolmodel.2021.109692

Wadoux, A. M. J.-C., Brus, D. J., Rico-Ramirez, M. A., & Heuvelink, G. B. (2019). Sampling design optimization for soil mapping with random forest. *Geoderma*, *355*, 113913. https://doi.org/10.1016/j.geoderma.2019.113913

Wadoux, A. M. J.-C., Minasny, B., & McBratney, A. B. (2020). Machine learning for digital soil mapping: Applications, challenges and suggested solutions. *Earth-Science Reviews*, *210*, 103359. https://doi.org/10.1016/j.earscirev.2020.103359

Wolpert, D. H. (1992). Stacked generalization. Neural Networks, 5(2), 241-259.

Zhang, Y., Qi, Z., Ma, N., Fu, Y., Yang, Y., & Xie, D. (2019). Comparison of machine-learning models for predicting short-term mortality in acute pancreatitis patients. *Medical Science Monitor*, *25*, 8639-8649. https://doi.org/10.12659/MSM.918638

Zhao, Z., Yang, Q., Ding, H., An, S., Xu, C., Cao, Y., & Wang, L. (2021). Soil organic matter prediction based on remote sensing data and random forest model in Shunyi district, China. *Environmental Earth Sciences*, *80*(11), 398. https://doi.org/10.1007/s12665-021-09695-8

Zhou, Z.-H. (2012). *Ensemble methods: Foundations and algorithms*. Chapman and Hall/CRC. https://doi.org/10.1201/b12207

Zinck, J. A., Metternicht, G., Del Valle, H. F., & Angelini, M. (2023). Geopedology: An Integration of Geomorphology and Pedology for Soil and Landscape Studies. Springer. Second Edition.